

Instituto Tecnológico y de Estudios Superiores de Monterrey

Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador

TC5035.10

Semana 3

Avance 1. Análisis exploratorio de datos

Equipo 52:

MNA A00449074 - Elda Cristina Morales Sánchez de la Barquera

MNA A01747706 - María Paula Gutiérrez Cervantes

MNA A01122243 - José Manuel Toral Cruz

Equipo docente:

Dra. Grettel Barceló Alonso – Profesora Titular

Dr. Luis Eduardo Falcón Morales – Profesor Titular

Mtra. Verónica Sandra Guzmán de Valle – Profesora Asistente

Patrocinador:

Dr. Gerardo Camacho

11 de mayo de 2026

Contenido

Introducción	2
Repositorio de Github	4
SCARED.....	4
Estructura	6
Ingesta de imágenes	10
Estructura de la información espacial	12
Análisis Exploratorio.....	18
Perfil radial de luminancia	19
Coeficiente de Variación (CoV)	20
Solución mínima: envolvente gaussiano	22
HAMLYN	24
Estructura	25
Análisis exploratorio	27
Respuesta sintética a la rúbrica	33
Conclusiones de HAMLYN	33
C3VDv2	34
Introducción	34
Diseño del pipeline para EDA.....	35
Análisis Exploratorio	36
Risk register y metodología de aseguramiento de calidad (CRISP-ML(Q))	51
Conclusiones	53
Referencias.....	54



Introducción

Los datos para la investigación en reconstrucción 3D endoscópica y la estimación de profundidades en cirugía mínimamente invasiva responden a una naturaleza semiestructurada y no tabular. Su consumo representa un conjunto de retos técnicos, y el modelaje con base en ellos no resulta directo: a diferencia de los datasets tabulares convencionales donde cada observación es una fila y cada variable una columna, los datos endoscópicos se organizan como secuencias de video estéreo, mapas de profundidad tridimensionales, nubes de puntos y archivos de calibración de cámara que deben interpretarse conjuntamente para tener significado clínico.

En el presente reporte afrontamos estos problemas y describimos tanto las estructuras que alojan los datos como las formas de su consumo. Ponemos énfasis en las estructuras porque, a diferencia de los datos tabulares o las bases de datos relacionales, los directorios que organizan los datos médicos endoscópicos contienen una gran diversidad de tipos de archivos, funciones y tamaños. Entender cómo se ordenan físicamente estos archivos en las carpetas es fundamental para poder extraer y emparejar sus contenidos de manera correcta. Por esta razón, este documento se divide en cuatro apartados fundamentales:

1. **Repositorio de Github:** Se presenta el entorno de trabajo y la ubicación centralizada de los recursos, códigos y herramientas desarrolladas para el consumo de los datos.
2. **Conjuntos de Datos (Datasets):** Se contextualizan las tres bases de datos clínicas empleadas. En primer lugar, **SCARED**, la cual ofrece mapas de profundidad reales capturados con luz estructurada sobre tejido porcino (Allan et al., 2021). En segundo lugar, **Hamlyn**, que provee secuencias endoscópicas estéreo *in-vivo* (Recasens et al., 2021). Finalmente, **C3VD** (*Colonoscopy 3D Video Dataset*), que aporta realismo clínico mediante maniqués con mapas de referencia a nivel de píxel (Golhar et al., 2025).
3. **Estructura:** Se describe la organización lógica de los archivos dentro de las carpetas de cada conjunto de datos. Esta sección detalla cómo se ordenan y vinculan los archivos de video, mapas de profundidad, nubes de puntos y metadatos de calibración para su procesamiento (Allan et al., 2021; Golhar et al., 2025).
4. **Análisis Exploratorio de Datos (EDA):** Se presenta una exploración estadística básica e inicial de las variables. El análisis se enfoca en cuantificar la volumetría de los datos (cantidad de videos, fotogramas y

resoluciones), identificar las distribuciones de los valores y evaluar la proporción de datos faltantes, documentando anomalías como el porcentaje de píxeles que carecen de información de referencia (*ground truth*) a causa de los reflejos especulares (Allan et al., 2021).

Repositorio de Github



https://github.com/jmtoral/proyecto_integrador_52

SCARED

El conjunto de datos SCARED (*Stereo Correspondence and Reconstruction of Endoscopic Data*) representa un hito metodológico en la validación de algoritmos de visión computacional y reconstrucción 3D aplicados a la endoscopia (Allan et al., 2021). A diferencia de enfoques previos basados en aproximaciones algorítmicas, simulaciones sintéticas o modelos anatómicos (*phantoms*) de realismo limitado, SCARED proporciona mediciones de referencia absolutas (*ground truth*) de profundidad topográfica densa con precisión milimétrica.

Para garantizar esta precisión, la recolección de datos se realizó *ex vivo* sobre la anatomía abdominal de cadáveres porcinos. Se empleó el endoscopio estéreo de un robot quirúrgico da Vinci Xi, acoplado temporalmente a un proyector de luz estructurada miniaturizado (Allan et al., 2021). Este proyector emitió patrones lumínicos codificados en códigos Gray de 10 bits, que asignan una firma óptica única a cada píxel de la escena. Con ello se resolvió el problema clásico de correspondencia en tejidos blandos de textura uniforme, permitiendo una triangulación matemática exacta de la topografía tridimensional antes de que los órganos sufrieran deformación o sangrado.

La fidelidad de este *ground truth* ha consolidado a SCARED como el benchmark de referencia para evaluar modelos avanzados de inteligencia artificial en cirugía endoscópica. Un ejemplo representativo es el trabajo de Shao et al. (2022), quienes lo emplearon para validar AF-SfMLearner, una red de estimación de profundidad y ego-movimiento basada en aprendizaje auto-supervisado. Dado que el entorno quirúrgico está caracterizado por variaciones de iluminación y reflejos especulares que rompen el supuesto de *constancia de brillo*, condición fundamental en visión computacional, Shao et al. (2022) introdujeron un módulo de *flujo de apariencia* (*appearance flow*) que permite a la red compensar las inconsistencias fotométricas entre fotogramas consecutivos. Sus resultados demostraron que es posible inferir

la estructura 3D del tejido blando a partir de una cámara monocular con una precisión comparable a la de los sistemas estéreo tradicionales.

La base de datos SCARED se utilizó durante la edición 2019 de la conferencia MICCAI (*Medical Image Computing and Computer-Assisted Intervention*). En este evento, diez equipos compitieron en el sub-reto de correspondencia estéreo endoscópica (*EndoVis Challenge*) con el objetivo de predecir mapas de profundidad densos. Las metodologías empleadas por los participantes evidencian una transición desde flujos de trabajo (*pipelines*) basados en métodos clásicos o variacionales hacia arquitecturas de Aprendizaje Profundo (*Deep Learning*), incluyendo el uso de modelos como PSMNet, UNet y Redes Generativas Antagónicas (CycleGAN). Dicho dataset se encuentra [disponible en Hugging Face](#).

La *Figura 1* presenta la tabla de los participantes del reto antes mencionado, ordenados según el desempeño evaluado mediante la métrica de Error Absoluto Medio (MAE) expresado en milímetros.

Para el análisis estructural y exploratorio de los datos de SCARED construimos dos notebooks, disponibles en el repositorio de Github. El primero se centra en la exploración estructural de las carpetas y en el entendimiento de qué datos se encuentran allí. Mientras tanto, el segundo se centra en la construcción de métricas para entender qué posibles preprocesos se requieran para el entrenamiento de modelos. Dichos repositorios se encuentran en los siguientes enlaces:

- Exploración de archivos y formatos:
https://github.com/jmtoral/proyecto_integrador_52/blob/main/notebooks/0_0_exploracion_scared.ipynb
- Análisis exploratorio desde la perspectiva de la iluminación no uniforme

Figura 1: Equipos y resultados del reto MICCAI 2019 (SCARED)


#	INSTITUCIÓN	PI	ARQUITECTURA	ERROR (MM)
1	Rediminds Inc. EUA	T. Zeffiro	PSMNet piramidal + interpolación gaussiana Red de correspondencia estéreo en pirámide multiescala. Rellena huecos con funciones gaussianas. estéreo profundo	3.47
2	Fraunhofer HHI Alemania	J. C. Rosenthal	Pipeline híbrido: CLAHE + patchRM + CNN Mejora contraste con CLAHE, estima por bloques con patchRM y completa zonas faltantes con una CNN. estéreo híbrido	4.05
3	Norwegian Univ. of Science and Technology Noruega	C. Wang	Disparidad variacional multiescala + filtro bilateral Método variacional clásico en pirámide de resoluciones. Filtro bilateral en post-proceso. variacional	4.28
4	Johns Hopkins University EUA	X. Zhang	PSMNet + SGBM + ICP con pérdida L1 PSMNet con SGBM clásico estéreo. ICP alinea la nube de puntos; pérdida L1. estéreo profundo	4.39
5	Univ. of Western Ontario Canadá	W. Xia	Volumen de costo multiescala + filtro mediano guiado Volumen 3D de costos de correspondencia en múltiples escalas (pérdida MSE). Filtro mediano guiado. CNN profunda	9.44
6	Sin afiliación —	K. Fu	DNN no supervisada + reproyección estéreo Red profunda sin etiquetas, minimizando diferencia fotométrica entre vistas. Profundidad por reproyección. no supervisado	17.22
7	Shenzhen Inst. Advanced Technology China	H. Luo	Encoder-decoder VGG con skip connections VGG modificado como encoder-decoder. Skip connections preservan detalles; suavizado de 4 vecinos. encoder-decoder	18.21
8	Shenzhen Inst. Advanced Technology China	X. Li	CycleGAN para síntesis de mapas de profundidad Red generativa antagónica en 2 etapas. Trata la profundidad como traducción imagen-a-imagen. GAN	20.52
9	Harbin Institute of Technology China	Z. Zhanshi	UNet 6 niveles con pérdida multiescala Pérdida combinada: similitud fotométrica + suavidad de disparidad + consistencia izquierda-derecha. UNet	21.20
10	Heidelberg University Alemania	L. Sharan	UNet con pérdida MAE y regularización de suavidad UNet estándar minimizando MAE con regularización de suavidad para evitar discontinuidades. UNet	48.72

Nota. Elaboración propia con base en Allan et al. (2021).

Estructura

El dataset SCARED se distribuye como una colección de archivos comprimidos independientes, uno por cada sesión de captura. La carpeta raíz contiene nueve datasets numerados del 1 al 9, con tamaños que oscilan entre 12.8 GB y 32.4 GB según la duración de las secuencias de video incluidas. Adicionalmente, se proporcionan dos versiones reducidas, `test_dataset_8.zip` (240 MB) y `test_dataset_9.zip` (378 MB), que contienen los mismos keyframes de los datasets de prueba pero sin los archivos `scene_points.tar.gz`, lo que los hace adecuados para verificar la integridad del pipeline de lectura sin descargar los datos completos.


Figura 2: Estructura general del dataset



Nota. Estructura interna de dataset_N.zip elaborada a partir de maxhallan7 (2024).

Cada archivo comprimido contiene cinco *keyframes* con estructura idéntica, con dos excepciones documentadas: el *keyframe_4* del *dataset_1* carece de la carpeta *data* debido a un error de *logging* durante la captura, y el *keyframe_5* de todos los *datasets* originales del reto no incluye datos de interpolación. Dentro de cada *keyframe* se distinguen dos niveles de información: los archivos en la raíz corresponden al instante preciso de la captura con luz estructurada y constituyen el *ground truth* de alta calidad, mientras que la carpeta *data* contiene la secuencia de video y los datos cinemáticos del robot, útiles para extender el entrenamiento a más frames pero con menor precisión geométrica.

Figura 3: Estructura interna de casa dataset



Nota. Elaboración propia con base en Allan et al. (2021) y maxhallan7 (2024).

La *Tabla 1* describe los nueve archivos presentes en cada keyframe del dataset SCARED (Allan et al., 2021). Los archivos de la raíz del keyframe, obtenidos mediante proyección de luz estructurada, constituyen la referencia de mayor precisión del dataset: `Left_Image.png` y `Right_Image.png` son las capturas RGB del par estéreo a resolución 1280×1024 píxeles; `left_depth_map.tiff` y `right_depth_map.tiff` almacenan en formato float32 las coordenadas tridimensionales (X, Y, Z) en milímetros para cada píxel, donde el valor (0, 0, 0) indica ausencia de medición por oclusión o reflejo especular; y `point_cloud.obj` contiene la geometría 3D sin interpolar, que sirve como referencia para el cálculo de la *Chamfer Distance*.

El archivo `endoscope_calibration.yaml` provee los parámetros intrínsecos de la cámara en formato *OpenCV*, aunque el README advierte que se trata de una calibración aproximada. Dentro de la carpeta `data` se encuentran tres recursos adicionales de menor precisión pero mayor volumen: el video `rgb.mp4` con los frames de ambas cámaras apilados verticalmente, el archivo `frame_data.tar.gz` con la transformación rígida de la cámara relativa al keyframe de origen, y `scene_points.tar.gz` con los mapas de profundidad proyectados a cada frame del video mediante warping cinemático, para los cuales el README advierte explícitamente que no constituyen ground truth perfecto.

Tabla 1: Descripción de los tipos de archivo que componen SCARED

Archivo	Formato	Qué contiene y para qué sirve
Left_Image.png	PNG · uint8	Entrada del modelo: Textura real y gradientes de luz para entrenar la corrección de iluminación.
Right_Image.png	PNG · uint8	Par estéreo: Vista complementaria que permite el cálculo de profundidad por disparidad.
left_depth_map.tiff	TIFF · float32	GT de profundidad (L): Coordenadas (X,Y,Z) en mm por píxel. Puntos sin señal se marcan como (0,0,0).
right_depth_map.tiff	TIFF · float32	GT de profundidad (R): Homólogo al izquierdo para validación o modelos que usen el par estéreo completo.
point_cloud.obj	OBJ · texto	Geometría base: Nube de puntos 3D pura capturada por el proyector sin interpolaciones previas.
endoscope_calibration.yaml	YAML	Calibración: Matriz K y distorsión. Permite convertir píxeles en rayos 3D. Puede tener errores leves.
data/rgb.mp4	MP4 · H.264	Video: Cámaras apiladas verticalmente. Sirve para extraer frames y generar datos mediante warping.
data/frame_data.tar.gz	TAR.GZ (JSON)	Cinemática: Rotación y traslación de la cámara por frame para proyectar la profundidad del keyframe.
data/scene_points.tar.gz	TAR.GZ (TIFF)	Warping Proyectado: Mapas de profundidad proyectados a cada frame. Útil para entrenamiento auxiliar.

Ingesta de imágenes

La pieza fundamental de este proyecto es la captura de imagen del tejido, que sirve como el dato de entrada para nuestro modelo. Utilizamos el formato PNG porque, a diferencia de otros formatos, no comprime la imagen con pérdida de información, preservando la fidelidad de los colores y texturas necesarios para el análisis médico.

Para que el sistema pueda "ver" en tres dimensiones, trabajamos con un par estéreo: dos fotos simultáneas (Left_Image.png y Right_Image.png) que capturan la misma escena desde ángulos ligeramente distintos.

Especificaciones Técnicas


- **Estructura del Array:** (1024, 1280, 3). Esto indica que la imagen se compone de 1024 filas de píxeles (alto) y 1280 columnas (ancho), con 3 capas de color (Rojo, Verde y Azul).
- **Resolución:** 1280×1024 px.
- **Tipo de Dato:** uint8. Es el formato estándar de imagen donde cada píxel tiene un valor entero entre 0 (negro total) y 255 (intensidad máxima).
- **Rango Utilizado:** Se observa el uso del rango completo [0, 255], lo que garantiza que estamos aprovechando toda la profundidad de color disponible.

Contexto Visual y Desafíos

Las imágenes muestran tejido digestivo porcino bajo la luz de un endoscopio. Al comparar las fotos izquierda y derecha, se nota un pequeño desplazamiento lateral; este fenómeno, llamado disparidad, es el que permite al modelo calcular la profundidad y reconstruir la geometría del órgano.

El mayor reto técnico que enfrentamos es el gradiente de iluminación: la luz es intensa en el centro pero se desvanece hacia los bordes. Corregir esta falta de uniformidad es el objetivo principal de este desarrollo, ya que una iluminación irregular puede confundir los algoritmos de reconstrucción 3D.

Figura 4: Imágenes en formato png del keyframe 1



Para la validación de los modelos de reconstrucción, se utiliza el archivo `left_depth_map.tiff`. A diferencia de las fotografías digitales comunes que solo almacenan información de color, este archivo funciona como una matriz de medición métrica. Utiliza un formato de alta precisión (punto flotante) para registrar la distancia exacta en milímetros de cada punto del tejido respecto al endoscopio. Esto transforma una imagen plana en un mapa de relieve real, permitiendo conocer dimensiones físicas precisas dentro de la cavidad digestiva.

Estructura de la información espacial

El archivo TIFF funciona como una matriz tridimensional de forma $(1024, 1280, 3)$, donde cada píxel indexa una coordenada proyectiva (X, Y, Z) en el espacio euclidiano. Para los fines de este reporte, se extrae exclusivamente el canal Z , el cual representa la profundidad ortogonal desde el plano de la cámara hacia la superficie del tejido.

Caracterización de un Fotograma de Control

A continuación, se describen los resultados obtenidos tras la inspección de un caso de prueba dentro del dataset (`keyframe_1`), el cual sirve para caracterizar el entorno de trabajo:

- **Precisión de Datos:** Los valores se almacenan como `float32`, garantizando que la resolución submétrica necesaria para aplicaciones quirúrgicas se mantenga sin errores de cuantización.

- **Dominio Espacial:** El análisis del canal Z revela un rango operativo de **[35.1, 176.3] mm**. La mediana de profundidad se sitúa en **58.6 mm**, lo que establece el plano de trabajo principal para el entrenamiento del modelo.

Dicho ejemplo se puede observar en este formato en los notebooks:

Figura 5: Imágenes en formato png del keyframe 1

```
=== TIFF crudo ===  
Forma:      (1024, 1280, 3) → (alto, ancho, canales XYZ)  
Tipo:       float32  
Rango X:    [-72.5, 80.9] mm  
Rango Y:    [-54.6, 61.6] mm  
Rango Z:    [35.1, 176.3] mm  
  
=== Canal Z (profundidad) ===  
Píxeles válidos: 1,027,266 de 1,310,720 (78.4%)  
Profundidad mín: 35.1 mm  
Profundidad med: 58.6 mm  
Profundidad máx: 176.3 mm
```

Interpretación de las Visualizaciones de Control


Como parte del proceso de auditoría de datos, se generaron tres diagnósticos visuales (ver Figura 7):

1. **Mapa de Densidad de Profundidad (Z-Map):** Mediante una escala cromática (Viridis), se normalizan los valores de 35 mm (amarillo) a 170 mm (morado). Esta visualización permite confirmar la continuidad estructural del tejido y detectar posibles discontinuidades en la captura.
2. **Segmentación de Validez (Validity Mask):** Se identifica que el **78.4%** de la imagen posee datos de profundidad válidos (codificados en verde). Las áreas en rojo corresponden a valores NaN o nulos, derivados de oclusiones, falta de iluminación periférica o superficies con propiedades ópticas no aptas para el sensor estéreo.
3. **Análisis Estadístico (Histograma):** La distribución de frecuencias confirma que la mayoría de los píxeles válidos se concentran cerca de la mediana (~59 mm), con una cola extendida hacia los 170 mm. Este comportamiento es típico en la topografía de las cavidades orgánicas, donde el fondo anatómico

se aleja progresivamente del punto de inserción y del rango de visión del endoscopio (Allan et al., 2021).

Este análisis preliminar es crítico, ya que asegura que el modelo de aprendizaje automático sea supervisado por datos métricamente consistentes y biológicamente coherentes.

Figura 7: Visualizaciones de control



Calibración de la cámara con el archivo YAML

El archivo `endoscope_calibration.yaml` es la pieza que permite traducir las fotos planas en medidas reales (milímetros) usando el estándar de OpenCV. Como se muestra en la Figura 6, su elemento clave es la matriz intrínseca K , que actúa como el "manual de instrucciones" de la cámara: define qué tanto se amplía la imagen (distancia focal) y dónde está el punto central por donde entra la luz (centro óptico).

Al analizar los datos, vemos que el centro por donde entra la luz está en las coordenadas (597, 520), mientras que el centro matemático de la pantalla es (640, 512). Esta diferencia de 43 píxeles nos indica que el lente no está perfectamente alineado con el sensor de la cámara. Este tipo de asimetría es muy común en los endoscopios debido a que son instrumentos tan pequeños que es físicamente casi imposible lograr que todas las piezas queden centradas a la perfección durante su fabricación.

La precisión de esta matriz es fundamental para métodos de representación como EndoGaussian, ya que estos algoritmos utilizan la matriz K para inicializar la nube de puntos mediante la reproyección de píxeles al espacio tridimensional y para definir el proceso de rasterización de los *Splatting* de Gaussianas. Sin una calibración que vincule los píxeles con rayos en el espacio 3D, el modelo no podría proyectar correctamente las características visuales del tejido sobre una estructura geométrica coherente. No obstante, dado que la calibración se considera una

aproximación, el diseño del sistema debe prever mecanismos de robustez o corrección de iluminación que operen directamente sobre la imagen para mitigar posibles inconsistencias en los parámetros de la matriz.

Figura 6: Información contenida en el YAML

```
=== Matriz intrínseca K (cámara izquierda) ===

fx = 1035.3 px    (focal horizontal)
fy = 1035.1 px    (focal vertical)
cx = 597.0 px     (centro óptico, eje X)
cy = 520.4 px     (centro óptico, eje Y)

Matriz completa:
[[1.0353081e+03 0.0000000e+00 5.9695502e+02]
 [0.0000000e+00 1.0350876e+03 5.2041003e+02]
 [0.0000000e+00 0.0000000e+00 1.0000000e+00]]

Resolución de la imagen: 1280×1024 px
Centro teórico del sensor: (640, 512) px
Centro óptico real:      (597.0, 520.4) px
```


OBJ: Nube de puntos

El archivo point_cloud.obj contiene la nube de puntos tridimensional capturada directamente por el proyector de luz estructurada. A diferencia de los archivos TIFF, que organizan la información en una cuadrícula de píxeles, el formato Wavefront OBJ almacena cada punto medido como una línea de texto con sus tres coordenadas en milímetros (v x y z). El archivo no contiene caras ni mallas trianguladas, únicamente los 1,310,720 vértices capturados, lo que lo convierte en la representación geométrica más directa y confiable del tejido disponible en el dataset.

Los rangos espaciales de la muestra analizada (dataset_1/keyframe_1) son -35.3 a 62.6 mm en X, -49.7 a 31.7 mm en Y, y 49.7 a 115.4 mm en Z. Vale la pena comparar estos valores con los del TIFF del mismo keyframe, cuyo canal Z abarca de 35.1 a 176.3 mm: el rango del OBJ es más estrecho porque este archivo solo incluye los puntos que el proyector de luz estructurada pudo triangular con alta confianza, mientras que el TIFF incorpora también los píxeles periféricos y más alejados, que son geoméricamente válidos pero presentan menor certeza de medición.

Las dos proyecciones 2D de la Figura 7 ilustran estas características geométricas desde ángulos complementarios. La proyección lateral XZ muestra que los puntos se distribuyen en bandas diagonales: a medida que aumenta X (el endoscopio apunta más hacia los lados), también aumenta Z (el tejido está más lejos), lo que refleja la curvatura convexa del órgano. La proyección frontal XY, por su parte, revela la forma ovalada del campo de visión del endoscopio, con mayor densidad de puntos en la zona central y una caída progresiva hacia los bordes, coherente con el viñeteado circular documentado en el análisis del TIFF. Esta nube de puntos es la referencia utilizada para calcular la Chamfer Distance, métrica que cuantifica qué tan fielmente los modelos como EndoGaussian o MonolIT reconstruyen la geometría 3D real del tejido.

Figura 6: Muestra de 8k puntos del archivo .obj



Seguimiento del Movimiento: Poses de Cámara (frame_data.tar.gz)

Este archivo contiene la "bitácora" de movimiento del endoscopio a través de 197 archivos JSON, correspondientes a cada cuadro del video grabado. Su función principal es registrar la trayectoria del instrumento; para ello, cada archivo almacena la posición y rotación exacta de la cámara en relación con el punto donde se tomó la imagen inicial (*keyframe*).

Además del movimiento, cada JSON incluye los datos de calibración (como la focal en ~ 1035 px y el centro óptico en ~ 597 px). El hecho de que esta información se repita en cada cuadro asegura que el sistema pueda corregir pequeñas variaciones dinámicas durante la operación. Sin estos datos de "pose", sería imposible para un

algoritmo saber cómo cambia la perspectiva del tejido mientras el médico mueve el endoscopio.

Proyección Geométrica: Profundidad Warpeada (scene_points.tar.gz)

Este es el componente más pesado del dataset (entre 2 y 6 GB), ya que contiene la geometría 3D proyectada para cada momento del video. A diferencia del *keyframe* original, estos archivos TIFF tienen una resolución vertical doble (2048 píxeles) porque apilan la información de las cámaras izquierda y derecha en un solo archivo.


Mediante un proceso matemático llamado *warping*, la profundidad medida al inicio se "proyecta" hacia la nueva posición de la cámara en cada cuadro. Un dato relevante es que la cobertura de información útil baja del 78% al 59% en el primer cuadro; esto sucede porque, al moverse la cámara, partes del tejido quedan fuera de su nuevo campo de visión. Es fundamental notar que estos archivos se consideran una "supervisión auxiliar" para el entrenamiento y no una verdad absoluta (*ground truth*), ya que el movimiento del robot y la sincronización del video pueden introducir pequeñas imprecisiones métricas.

Visualización Final: Integración RGB y Profundidad

Como se observa en la Figura 8, la relación entre la imagen visual y los datos métricos se hace evidente al superponer el mapa de profundidad sobre la foto original. Esta visualización revela que las zonas donde falta información (espacios vacíos en el mapa) coinciden exactamente con los puntos de mayor brillo en el tejido. Estos son reflejos especulares donde la humedad del órgano actúa como un espejo, impidiendo que el sistema de luz estructurada del endoscopio pueda calcular la distancia.

El mapa resultante muestra una coherencia biológica y física clara: los valores de profundidad más bajos (cerca de 50 mm) se encuentran en el centro, indicando que esa zona es la más cercana al lente. Conforme nos desplazamos hacia los bordes, la profundidad aumenta hasta los 80 mm o más, dibujando la curvatura natural del órgano. Esta transición coincide con el gradiente de iluminación: las zonas más alejadas son también las más oscuras, confirmando que la luz del endoscopio pierde intensidad de manera radial y predecible según la distancia al objetivo.

Figura 7: Integración de RGB y profundidad



Análisis Exploratorio

En el análisis exploratorio anterior (`00_exploracion_scared.ipynb`), revisamos cómo está organizado el conjunto de datos SCARED. Detallamos qué archivos contiene cada *keyframe*, el tamaño de las imágenes, los valores del mapa de profundidad y cómo está calibrada la cámara. Con eso quedó claro qué datos tenemos y cómo leerlos correctamente.

El notebook `01_eda_iluminacion.ipynb` da un paso más y analiza si es buena idea usar las imágenes RGB "crudas" (tal cual salen del endoscopio) como entrada directa para los modelos de estimación de profundidad. En visión por computadora, las redes neuronales suelen asumir que la iluminación es constante en toda la escena. Sin embargo, en una endoscopia esto no se cumple: la cámara está muy cerca del tejido, en constante movimiento y sobre superficies húmedas, lo que provoca cambios drásticos de luz (Espinosa et al., 2025). Si no se controlan estos defectos de iluminación, el modelo se confunde y asume que las sombras o los brillos son formas físicas del órgano, generando mapas de profundidad equivocados y perdiendo los detalles finos de la anatomía (Espinosa et al., 2025).

El principal problema que vamos a analizar es la iluminación desigual. Como la luz del endoscopio sale del mismo lugar que la cámara, el centro de la imagen siempre se ve muy iluminado y los bordes se oscurecen rápidamente (Espinosa et al., 2025; Ou et al., 2025). Este efecto es un problema de la óptica de la cámara, no de la forma real del tejido. Por lo tanto, el objetivo de este análisis es medir qué tan grave es este problema, ver en qué *keyframes* afecta más y comprobar si estos bordes oscuros están directamente relacionados con la pérdida de datos de referencia o *ground truth* (Allan et al., 2021).

Comprobar esta relación nos dará el argumento principal para justificar por qué es necesario aplicar una etapa de corrección de iluminación (o corrección fotométrica) antes de entrenar los modelos. Este paso de limpieza es clave para ayudar a la red neuronal a separar la forma tridimensional real del tejido de los efectos engañosos que provoca la luz del endoscopio (Espinosa et al., 2025).


Perfil radial de luminancia

Antes de proponer cualquier método de corrección de iluminación, es necesario describir la forma del problema para entender su comportamiento. El objetivo es determinar si el gradiente de luz es uniforme, si varía según los movimientos de la cámara, o si cae de forma suave o abrupta hacia la periferia. Para cuantificar esto, se utiliza la *luminancia*: la métrica estándar para medir el brillo percibido en una imagen a color. En lugar de usar un promedio matemático, la luminancia pondera los canales RGB de acuerdo con la sensibilidad del ojo humano a cada color mediante la fórmula estándar ITU-R BT.601: $Y = 0.299R + 0.587G + 0.114B$. Esta métrica se prefiere sobre el brillo bruto porque refleja de manera mucho más fiel lo que los modelos de visión por computadora "ven" al procesar la escena (Gonzalez & Woods, 2018).

Esto se logra agrupando los píxeles en función de su distancia respecto al centro geométrico del sensor. Por ejemplo, dado que las imágenes del conjunto de datos SCARED tienen una resolución de 1280x1024 píxeles (Allan et al., 2021), el centro exacto se ubica en la coordenada (640, 512). Al agrupar los píxeles en "anillos" concéntricos de 5 píxeles de anchura y promediar su luminancia, se obtiene una curva que muestra cuánta luz capta el sensor conforme nos alejamos del centro.

Al replicar este cálculo para los cinco keyframes del dataset_1, los resultados (visibles en la Figura 8) revelan un patrón consistente. Todas las curvas de luminancia comparten la misma forma: inician con valores muy altos en el centro de la imagen (entre 140 y 180 unidades, en una escala de 0 a 255) y descienden de manera continua hacia los bordes, donde se estancan en valores muy oscuros (entre 40 y 80 unidades). Esta caída gradual y sin interrupciones abruptas confirma empíricamente que el origen del gradiente es estrictamente óptico. Es decir, los bordes oscuros no son producto de la profundidad o la forma de la anatomía, sino un defecto físico provocado por la fuente de luz del endoscopio, la cual irradia con fuerza desde el centro del lente y pierde intensidad rápidamente hacia la periferia (Ou et al., 2025; Yu et al., 2024).

Figura 7. Perfil radial de luminancia y ratio centro/borde por keyframe.




Nota. Elaboración propia. Izquierda: perfil de luminancia promedio por distancia radial para los cinco keyframes de dataset_1. Derecha: ratio entre la luminancia del centro y la del borde de cada keyframe.

Coeficiente de Variación (CoV)

Para comparar estos fotogramas de forma rápida y determinar objetivamente en el reporte final cuál resultó más problemático, es indispensable contar con un único valor que resuma el estado general de la iluminación. El Coeficiente de Variación (CoV) cumple su rol. En la literatura de procesamiento de imágenes y visión computacional, el CoV es una métrica estadística estándar que evalúa qué tan variable es la iluminación en relación con su nivel promedio (Gonzalez & Woods, 2018; Joseph et al., 2023). Un CoV cercano a 0 significa que la iluminación es perfectamente plana, mientras que valores más altos indican que la imagen es altamente heterogénea (Nie et al., 2023). Su principal ventaja sobre el ratio centro/borde es que no asume que el problema es exclusivamente radial; por el contrario, captura cualquier fuente de variabilidad espacial en la escena, incluyendo reflejos especulares, sombras anatómicas o bordes oscuros (Ou et al., 2025).

Metodológicamente, el CoV se define como el cociente entre la desviación estándar y la media de la luminancia en toda la imagen, expresado matemáticamente como $\text{CoV} = \text{std}(\text{luminancia}) / \text{mean}(\text{luminancia})$ (Joseph et al., 2023; Nie et al., 2023). La Figura 5 presenta estos tres indicadores de iluminación a través de gráficas de barras ordenadas de mayor a menor CoV.

Figura 5. Resumen de indicadores de iluminación por keyframe.



Nota. Elaboración propia. Izquierda: CoV (std/mean de luminancia). Centro: ratio luminancia centro/borde. Derecha: porcentaje de especulares detectados. Barras ordenadas de mayor a menor CoV.

Tabla 3. Tabla resumen de indicadores de iluminación por keyframe, ordenada de mayor a menor CoV

Keyframe	Lum. media	Lum. std	CoV	Ratio C/B	Especulares (%)	GT válido (%)
KF5	93.2	61.9	665	2.72x	0.43	71.9
KF3	98.9	54.9	555	3.26x	1.57	86.8
KF4	97.4	50.7	521	3.22x	0.71	73.0
KF2	101.4	51.0	504	2.03x	0.91	83.0
KF1	97.6	48.0	492	1.33x	1.12	78.4

Como se observa en los resultados, KF5 encabeza el ranking con un CoV de 0.665, a pesar de tener la luminancia media más baja (93.2) y el menor porcentaje de píxeles especulares (0.43%). Su alta variabilidad interna se debe a que contiene zonas muy oscuras en los bordes y zonas relativamente brillantes en el centro; una severa diferencia óptica que la desviación estándar de 61.9 logra reflejar adecuadamente. Por su parte, KF3 y KF4 tienen los ratios centro/borde más extremos (3.26x y 3.22x) pero una desviación estándar global algo menor, lo que los coloca en segundo y tercer lugar de heterogeneidad. Finalmente, KF1 es el *keyframe* con la iluminación más regular, con un ratio de 1.33x y un CoV de 0.492. Sin embargo, el hecho de que incluso el fotograma mejor iluminado posea este nivel de dispersión demuestra que las imágenes endoscópicas crudas están lejos de la uniformidad, justificando plenamente la necesidad de integrar algoritmos de

corrección fotométrica (como MonolIT) antes de cualquier tarea de reconstrucción 3D (Espinosa et al., 2025).

Solución mínima: envolvente gaussiano

Hasta este punto, el análisis exploratorio ha caracterizado físicamente la presencia del gradiente de iluminación. Esta sección tiene un propósito metodológico específico: demostrar que el artefacto es tratable mediante técnicas de procesamiento espacial básico antes de invertir recursos computacionales en modelos de reconstrucción más complejos. Establecer esta prueba de concepto proporciona una línea base (baseline) cualitativa y cuantitativa; si una corrección elemental logra una mejora visible, se justifica la viabilidad del problema y la necesidad de buscar métodos más sofisticados.

El método seleccionado como prueba de concepto es la corrección de sombreado (shading correction). En el procesamiento de imágenes, se asume que una imagen capturada es el producto matemático de la textura perfecta del objeto multiplicada por un patrón de luz desigual (Gonzalez & Woods, 2018; Ou et al., 2025). Por lo tanto, aislando la forma de la luz (la "envolvente") y dividiendo la imagen original entre dicho mapa, es posible cancelar el efecto del gradiente y nivelar la iluminación (Gonzalez & Woods, 2018).

Esta corrección se aplicó sobre el keyframe 5 (KF5), identificado previamente como el de mayor CoV. Para estimar la envolvente de iluminación de este fotograma, se aplicó un filtro paso bajo Gaussiano con una desviación estándar (sigma) de 60 píxeles sobre su mapa de luminancia. Este nivel de difuminado destruye los detalles anatómicos finos, dejando únicamente la forma general de la luz del endoscopio (Gonzalez & Woods, 2018). Posteriormente, la envolvente se normalizó al rango y se dividió cada canal RGB de la imagen original por esta matriz. Los valores resultantes se recortaron al rango de intensidad válido. A la par de la comparación visual, se calculó el CoV antes y después del procesamiento para obtener una medida cuantitativa del cambio.

Para medir el éxito de este proceso de manera objetiva, se evaluó el cambio en la dispersión de la luz. Antes de la corrección, la imagen original presentaba un CoV de 0.6647, reflejando una falta de uniformidad severa debido al oscurecimiento de los bordes. Tras aplicar la división por la envolvente gaussiana, el valor descendió drásticamente a 0.2272. Esto representa una reducción del 65.8% en la no-uniformidad de la luz, lo cual comprueba de manera cuantitativa que la operación matemática fue altamente efectiva para aplanar la iluminación en la escena.

La Figura 9 presenta los resultados cualitativos de este proceso, mostrando la imagen original de KF5, la imagen corregida y un mapa de diferencias absolutas amplificado por un factor de 3 para facilitar su inspección visual.

Figura 9. Demostración cualitativa de corrección de iluminación sobre KF5.




Nota. Elaboración propia. Izquierda: imagen original de KF5. Centro: imagen corregida por división de envolvente gaussiana ($\sigma=60$). Derecha: diferencia absoluta amplificada por un factor de 3, donde el amarillo indica mayor cambio.

En la imagen corregida es posible observar que el tejido del borde inferior izquierdo, el cual era prácticamente negro en la captura original, recupera detalle y textura visible. Como lo indica el color amarillo en el mapa de diferencias, los cambios más drásticos ocurren precisamente en los bordes, donde la envolvente estimada era baja y la corrección matemática fue más agresiva. En contraste, el centro de la imagen cambia muy poco debido a que su iluminación original ya era brillante y la envolvente en esa zona se aproximaba a 1.

Sin embargo, esta corrección básica introduce un nuevo artefacto: un cambio de tonalidad hacia colores más fríos (tonos rosados y azulados). Este fenómeno es consecuencia de aplicar la corrección de forma independiente canal por canal. Dado que la envolvente de luz se estimó de manera global sobre la luminancia, la división altera la proporción original de las bandas RGB, modificando el balance de color. Esta limitación cromática demuestra que, aunque el problema geométrico de la luz es tratable, se requieren modelos fundacionales más avanzados para las siguientes etapas del proyecto, los cuales sean capaces de lograr la invariancia a la iluminación sin sacrificar la fidelidad de los colores clínicos (Espinosa et al., 2025; Ou et al., 2025). La figura 10 muestra una ilustración de cómo funciona esta corrección.

Figura 10: Corrección de iluminación mediante envolvente gaussiano.



Nota. Figura elaborada con asistencia de inteligencia artificial generativa (OpenAI, ChatGPT/DALL·E) y basada en técnicas de corrección de iluminación descritas en Gonzalez y Woods (2018).

HAMLYN

El [conjunto de datos HAMLYN](#) constituye una base relevante para el análisis de imágenes endoscópicas en escenarios quirúrgicos más cercanos a condiciones reales (Recasens et al., 2021). A diferencia de SCARED, cuyo valor principal se encuentra en la disponibilidad de mapas de profundidad de alta precisión obtenidos mediante luz estructurada sobre tejido porcino ex vivo (Allan et al., 2021), HAMLYN ofrece secuencias endoscópicas estéreo in vivo, lo cual permite observar condiciones visuales más complejas: movimiento de cámara, variaciones de iluminación, deformaciones del tejido, baja textura, reflejos especulares, oclusiones parciales y cambios en la profundidad aparente de la escena (Recasens et al., 2021)-

Para este avance se utilizó la versión rectificada de HAMLYN asociada al proyecto Endo-Depth-and-Motion (Recasens et al., 2021). Esta decisión metodológica responde a que las imágenes rectificadas facilitan el análisis estéreo, ya que alinean geoméricamente los pares izquierdo y derecho para simplificar la correspondencia

entre píxeles. En términos prácticos, la rectificación permite que los puntos equivalentes entre ambas vistas se busquen principalmente sobre la misma línea horizontal o de escaneo, reduciendo la complejidad del cálculo de disparidad y profundidad (Allan et al., 2021)

Esta versión resulta adecuada para el análisis exploratorio porque permite concentrarse en la volumetría, la resolución, la calidad visual, la validez de los mapas de profundidad y la preparación de los datos para modelos de estimación de profundidad. El uso de HAMLYN dentro del proyecto permite complementar el análisis realizado con SCARED. Mientras SCARED aporta una referencia geométrica controlada para evaluar reconstrucción 3D (Allan et al., 2021), HAMLYN permite valorar la robustez del flujo de procesamiento frente a datos endoscópicos con mayor variabilidad visual (Recasens et al., 2021) Esta distinción es importante porque el documento de avance establece que los datos endoscópicos no se comportan como bases tabulares convencionales, sino como datos semiestructurados compuestos por secuencias, imágenes, mapas de profundidad y archivos de calibración que deben interpretarse conjuntamente para tener significado clínico y computacional

Estructura

El dataset HAMLYN rectificado fue organizado en cinco secuencias: rectified01, rectified04, rectified05, rectified06 y rectified08. Para cada secuencia se descargaron y descomprimieron archivos de imágenes RGB y mapas de profundidad, además de sus respectivos archivos de calibración intrínseca. La estructura local se mantuvo separada en carpetas de archivos comprimidos, archivos de calibración y datos extraídos, con el propósito de conservar trazabilidad y evitar mezclar los datos crudos con las salidas del análisis.


Figura 11. Estructura general del dataset HAMLYN rectificado.

```
data/hamlyn/  
├─ raw_zip/  
├─ intrinsics/  
└─ extracted/  
    ├─ rectified01/  
    ├─ rectified04/  
    ├─ rectified05/  
    ├─ rectified06/  
    └─ rectified08/
```

Nota. Elaboración propia a partir de la organización local del dataset descargado desde la versión rectificada de HAMLYN.

El análisis exploratorio identificó una relación consistente entre imágenes RGB y mapas de profundidad. En total, el dataset procesado contiene pares imagen–profundidad distribuidos por secuencia. Las imágenes RGB están almacenadas en formato JPEG, mientras que los mapas de profundidad se encuentran en formato PNG de 16 bits (I;16). Las secuencias rectified01, rectified06 y rectified08 tienen resolución de 640×480 píxeles; por su parte, rectified04 y rectified05 tienen resolución de 360×288 píxeles. Esta heterogeneidad en resolución es relevante porque implica que cualquier etapa posterior de entrenamiento deberá considerar redimensionamiento, normalización o estrategias de entrada compatibles entre secuencias.

Figura 12. Visualización de control para la secuencia rectified06 de HAMLYN.



Nota. La figura muestra una imagen RGB rectificada, el mapa de profundidad normalizado, la máscara de píxeles válidos y la distribución de profundidad válida. Elaboración propia con base en el análisis exploratorio del dataset HAMLYN.

La distribución de archivos también muestra diferencias importantes de volumen. `rectified08` concentra la mayor parte del dataset, con 28,786 imágenes JPEG y 28,786 mapas PNG; en contraste, `rectified05` contiene 1,798 imágenes JPEG y 1,798 mapas PNG. Las demás secuencias se ubican en un rango intermedio: `rectified01` contiene 2,116 pares, `rectified04` contiene 3,146 pares y `rectified06` contiene 2,474 pares imagen–profundidad. Esta distribución confirma que HAMLYN no es homogéneo en tamaño por secuencia, por lo que el análisis y el entrenamiento de modelos deben controlar el posible sesgo inducido por la sobrerrepresentación de `rectified08`.

La estructura de trabajo quedó documentada en el repositorio de GitHub mediante el notebook `02_hamlyn_edu.ipynb`, así como mediante las salidas generadas en las carpetas `outputs/hamlyn/tables` y `outputs/hamlyn/figures`. Esto mantiene la continuidad con la metodología aplicada previamente a SCARED, donde el avance distingue entre la exploración estructural de los archivos y la construcción de métricas para identificar posibles preprocesamientos antes del modelado.


Análisis exploratorio

El análisis exploratorio de HAMLYN se diseñó para responder las preguntas guía de la rúbrica: valores faltantes, estadísticas resumidas, valores atípicos, cardinalidad de variables categóricas, distribuciones sesgadas, tendencias temporales, correlaciones, distribución por categorías, necesidad de normalización y posible desequilibrio en la variable objetivo. Esta lógica es coherente con el avance del proyecto, donde se señala que el EDA debe cuantificar la volumetría de los datos, identificar distribuciones, evaluar la proporción de datos faltantes y documentar anomalías en la referencia de profundidad.

En relación con los valores faltantes, HAMLYN presenta píxeles inválidos o fuera del rango definido como profundidad válida. Para este análisis se consideró como rango inicial de referencia una profundidad entre 1 mm y 300 mm. Bajo este criterio, la cobertura válida varía considerablemente entre secuencias. `rectified06` presenta el mayor porcentaje promedio de píxeles válidos, con 79.27%, seguida por `rectified01`, con 72.83%. En contraste, `rectified08` presenta la menor cobertura, con 35.40% de píxeles válidos, mientras que `rectified05` alcanza 46.26% y `rectified04`

53.06%. Estos resultados sugieren que la calidad geométrica no depende únicamente del número de imágenes disponibles, sino también de la textura de la escena, las condiciones de iluminación, la presencia de reflejos, las oclusiones y el desempeño del proceso de correspondencia estéreo.


Figura 13. Visualización de control para la secuencia rectified08 de HAMLYN.



Nota. La secuencia rectified08 presenta la mayor volumetría del dataset, pero una menor proporción promedio de profundidad válida, lo que evidencia la necesidad de filtrar o enmascarar valores inválidos antes del modelado.

Las estadísticas resumidas de profundidad también muestran diferencias relevantes. La profundidad media válida fue de 79.48 mm para rectified01, 43.59 mm para rectified04, 46.18 mm para rectified05, 115.68 mm para rectified06 y 70.64 mm para rectified08. La profundidad mediana sigue un patrón similar, aunque no idéntico, lo que sugiere distribuciones con distinto grado de dispersión y posible sesgo por secuencia. La desviación estándar promedio de profundidad fue particularmente alta en rectified06 y rectified08, lo que indica mayor variabilidad espacial en las escenas o mayor heterogeneidad en la profundidad estimada.


Figura 14. Porcentaje promedio de píxeles de profundidad válida por secuencia.



Nota. El porcentaje de profundidad válida varía de manera importante entre secuencias, lo que sugiere diferencias en calidad geométrica, textura, iluminación u oclusiones.

En cuanto a las imágenes RGB, se observaron diferencias de intensidad entre secuencias. La intensidad promedio fue de 95.10 en rectified01, 74.21 en rectified04, 82.56 en rectified05, 106.65 en rectified06 y 81.60 en rectified08. Aunque todas las secuencias utilizan el rango completo de intensidad $[0, 255]$, las diferencias en intensidad media y desviación estándar justifican la necesidad de aplicar normalización o estandarización antes de entrenar modelos. Esto es consistente con las buenas prácticas de análisis de imágenes, donde la señal, el rango dinámico y la saturación son criterios importantes para cuantificar adecuadamente una imagen, especialmente cuando se comparan datos obtenidos en condiciones distintas.

Figura 15. Profundidad media válida por secuencia en HAMLIN.




Nota. Las diferencias de profundidad media entre secuencias sugieren variación en distancia cámara-tejido y condiciones geométricas de captura.

La cardinalidad categórica del dataset quedó definida por cinco secuencias, dos modalidades funcionales principales —imagen RGB y mapa de profundidad—, dos extensiones principales —JPEG y PNG— y dos resoluciones dominantes. Esta clasificación es útil porque permite ordenar el análisis por categorías estructurales y no únicamente por archivos individuales. Además, confirma que el dataset no debe tratarse como una tabla convencional, sino como una colección semiestructurada de datos visuales y geométricos.

El análisis temporal se realizó mediante un índice aproximado de frame construido a partir del orden de los archivos dentro de cada secuencia. Con ello se analizaron tendencias en intensidad promedio, porcentaje de profundidad válida y profundidad media válida. En general, las pendientes temporales fueron pequeñas, lo que sugiere que no existe una tendencia lineal fuerte en todas las secuencias; sin embargo, sí se observan variaciones internas relevantes. Por ejemplo, rectified08 presenta una desviación estándar alta tanto en intensidad RGB como en porcentaje de profundidad válida, lo que indica una variabilidad temporal importante. rectified06, por su parte, muestra la mayor profundidad media y también una variabilidad considerable en profundidad, lo que puede asociarse con cambios de escena, distancia al tejido o movimiento del endoscopio.


Figura 16. Tendencia temporal del porcentaje de profundidad válida por secuencia.



Nota. El índice de frame se construyó a partir del orden de los archivos. La figura permite observar cambios en la cobertura geométrica válida a lo largo de las secuencias endoscópicas.

La correlación exploratoria permitió analizar la relación entre variables visuales y geométricas. La intensidad media RGB mostró una correlación positiva moderada con el porcentaje de píxeles válidos de profundidad ($r = 0.5363$), lo que sugiere que mejores condiciones de iluminación o mayor intensidad promedio podrían favorecer la disponibilidad de profundidad válida. También se observó una correlación positiva entre porcentaje de profundidad válida y profundidad media válida ($r = 0.5090$), así como entre profundidad media y profundidad mediana ($r = 0.9913$). Estas correlaciones no deben interpretarse como causalidad, sino como evidencia exploratoria de que la calidad visual y la calidad geométrica pueden estar relacionadas en datos endoscópicos rectificados.

Figura 17. Matriz de correlación exploratoria entre variables visuales y geométricas.



Nota. La matriz muestra relaciones entre intensidad RGB, saturación, porcentaje de profundidad válida y estadísticas de profundidad. Las correlaciones son exploratorias y no implican causalidad.

Respecto a los valores atípicos, el notebook generó archivos específicos para identificar posibles anomalías en profundidad y en RGB. En profundidad, los casos críticos se relacionan principalmente con bajo porcentaje de píxeles válidos. En RGB, los posibles valores atípicos se asocian con saturación o exceso de valores en cero. Estas condiciones son esperables en imágenes endoscópicas, donde la iluminación focal, los reflejos especulares, las zonas oscuras en bordes y las variaciones en la distancia del endoscopio al tejido pueden generar regiones con señal visual limitada.

En relación con el desequilibrio de clases, HAMLYN no corresponde a una base de clasificación categórica tradicional. Por ello, no existe una variable objetivo discreta con clases balanceadas o desbalanceadas. La variable objetivo funcional es continua: la profundidad por píxel. No obstante, sí se identifica un desequilibrio

relevante en la cobertura de profundidad válida entre secuencias, particularmente por la baja proporción de píxeles válidos en rectified08 y por la alta concentración de archivos en esa misma secuencia. Este hallazgo debe considerarse antes del entrenamiento, ya que podría inducir sesgo en el modelo si las secuencias se mezclan sin control.

Respuesta sintética a la rúbrica

Tabla 4. Respuestas a preguntas guía

Pregunta guía	Hallazgo en HAMLYN
¿Hay valores faltantes?	Sí. Se manifiestan como píxeles de profundidad inválidos o fuera del rango válido. La ausencia varía por secuencia.
¿Cuáles son las estadísticas resumidas?	Se calcularon métricas por secuencia para RGB y profundidad: número de archivos, resolución, intensidad media, saturación, profundidad media, mediana, desviación estándar y porcentaje válido.
¿Hay valores atípicos?	Sí. Se identifican posibles outliers por baja cobertura de profundidad válida, saturación RGB o exceso de valores cero.
¿Cuál es la cardinalidad de las variables categóricas?	Cinco secuencias, dos modalidades principales, dos formatos predominantes y dos resoluciones dominantes.
¿Existen distribuciones sesgadas?	Sí. Los histogramas de profundidad y las diferencias entre media y mediana sugieren dispersión desigual por secuencia.
¿Se identifican tendencias temporales?	Sí. Se analizaron cambios por frame en intensidad, profundidad válida y profundidad media; las pendientes son pequeñas, pero existe variabilidad temporal por secuencia.
¿Hay correlación entre variables dependientes e independientes?	Sí. Se calcularon correlaciones exploratorias entre variables visuales y geométricas. La intensidad media presenta correlación positiva moderada con profundidad válida.
¿Cómo se distribuyen los datos por categorías?	Los datos se distribuyen por secuencia, modalidad, extensión, resolución y cobertura de profundidad válida.
¿Se deberían normalizar las imágenes?	Sí. Las diferencias de intensidad entre secuencias justifican normalización para visualización y estandarización para modelado.
¿Hay desequilibrio en clases?	No aplica en sentido clásico; la profundidad es continua. Sin embargo, sí existe desequilibrio en volumen y cobertura válida por secuencia.

Nota. Elaboración propia a partir de los resultados obtenidos y las preguntas de investigación.

Conclusiones de HAMLYN

El análisis exploratorio de HAMLYN rectificado confirma que se trata de una base útil para evaluar modelos de visión computacional en condiciones endoscópicas

realistas. Su principal aportación al proyecto es la disponibilidad de secuencias estéreo rectificadas con mapas de profundidad asociados, lo que permite estudiar la relación entre textura visual y geometría de la escena. Sin embargo, el dataset presenta heterogeneidad relevante en volumen, resolución, intensidad y cobertura de profundidad válida.

La secuencia rectified08 representa el mayor reto metodológico, debido a que concentra la mayor cantidad de archivos pero presenta la menor proporción promedio de profundidad válida. Esto obliga a considerar estrategias de muestreo, filtrado o ponderación durante etapas posteriores de entrenamiento. Por otro lado, rectified06 ofrece la mayor cobertura de profundidad válida, aunque también presenta una profundidad media y variabilidad geométrica superiores al resto.

En términos de preprocesamiento, los resultados justifican normalizar las imágenes RGB, filtrar o enmascarar píxeles de profundidad inválidos, conservar la trazabilidad por secuencia y evitar mezclar indiscriminadamente todos los frames durante la partición de entrenamiento y validación. La estructura temporal de HAMLYN también sugiere que el análisis por frame puede aportar información relevante sobre estabilidad visual, movimiento y calidad geométrica.

En conjunto, HAMLYN complementa a SCARED porque aporta variabilidad visual y realismo quirúrgico. Su análisis permite anticipar decisiones críticas de preprocesamiento, como normalización RGB, filtrado de profundidad inválida, control por secuencia y partición cuidadosa de entrenamiento-validación para evitar sesgos por volumen o calidad geométrica. Por ello, su incorporación fortalece la evaluación del proyecto, ya que permite contrastar el desempeño del flujo de visión computacional en datos más heterogéneos y cercanos a condiciones endoscópicas reales.

C3VDv2

Introducción

El **Colonoscopy 3D Video Dataset versión 2 (C3VDv2)**, publicado por Golhar et al. (Johns Hopkins University, 2025), constituye un benchmark para el desarrollo y evaluación cuantitativa de algoritmos de reconstrucción tridimensional, estimación de profundidad y seguimiento de cámara en colonoscopia monocular. Comprende 192 secuencias de video que totalizan 169,371 cuadros, adquiridas imageando

phantoms de silicona de alta fidelidad con un colonoscopio clínico Olympus CF-HQ190L montado sobre un brazo robótico UR-3e de seis grados de libertad.

A diferencia de los datasets sintéticos renderizados, C3VDv2 preserva el pipeline óptico completo de un endoscopio clínico, lente fisheye, post-procesamiento del procesador de video, modelo de iluminación interno, mientras proporciona mapas de ground truth a nivel de píxel derivados del modelo 3D conocido de cada phantom mediante un procedimiento de registro 2D/3D basado en extracción de bordes. El dataset se distribuye bajo licencia CC BY 4.0.

Objetivo del análisis

El propósito del análisis exploratorio es caracterizar el dataset de manera tal que permita planear con rigor el experimento comparativo, identificando: la estructura jerárquica del dataset, las afirmaciones que el paper original hace y que conviene validar, los sesgos espaciales y de clase que afectarán al entrenamiento, y los videos que constituyen sub-muestras representativas para cada uno de los métodos a comparar.

Diseño del pipeline para EDA

El pipeline se estructuró como una secuencia de siete etapas, cada una respondiendo preguntas específicas del checklist exploratorio estándar (valores faltantes, estadísticas resumidas, outliers, cardinalidad, sesgos distribucionales, tendencias temporales, correlaciones dependiente/independiente, distribución bivariada, normalización de imágenes, balance de clase objetivo):

- Etapa 1: Integridad, esquema y valores faltantes. Higiene de cadenas, validación referencial, mapa de nulos y clasificación entre missingness estructural versus anómalo.
- Etapa 2: Análisis univariado de metadatos. Distribuciones individuales, detección de outliers, coeficientes de sesgo, recomendaciones de transformación.
- Etapa 3: Análisis bivariado y multivariado. Matriz de correlación con significancia estadística, validación cruzada de los sistemas de score, distribución de scores por escenario clínico (tags).
- Etapa 4: Análisis cinemático intra-video. Trayectorias de cámara 6-DoF derivadas de pose.txt, estadísticas de desplazamiento y rotación, evaluación de viabilidad por método.

- Etapa 5: Análisis multimodal a nivel de píxel. Inspección de RGB, mapas de profundidad y vectores normales del ground truth.
- Etapa 6: Sesgo espacial y balance de la variable objetivo. Distribución de profundidad absoluta sobre las regiones útiles de la imagen.
- Etapa 7: Síntesis y recomendaciones para siguiente fase del proyecto.

Como variable objetivo se eligió la estimación de profundidad monocular (regresión sobre el mapa de profundidad por píxel), bajo el argumento de que es la tarea que: (i) cuenta con ground truth directo y registrado a nivel de píxel en C3VDv2, (ii) los tres métodos a comparar producen como salida nativa o derivada, y (iii) dispone de un vocabulario de métricas establecido en la literatura (AbsRel, RMSE, RMSElog, δ -accuracies).

Análisis Exploratorio

Etapa 1. Integridad, esquema y valores faltantes

Resultados

La carga del archivo Excel arrojó 192 videos. La higiene de cadenas eliminó dobles espacios, normalizó casos y corrigió la tipografía 'zizag' → 'zigzag' en la columna Tags. La columna Segment se desambiguó por colon (c1 tiene sigmoid1/sigmoid2; c2 tiene un único sigmoid; son segmentos anatómicos distintos).

La distribución por tipo de video confirma la estructura documentada en el paper:

v1: 63 videos

v2: 57 videos

v3: 57 videos

v4: 15 videos

Diagnóstico de missingness estructural

Se verificó que los patrones de nulos del dataset son explicables por su diseño, no por errores de captura.

Columna	Tipo de video	n nulos	Justificación estructural
Quantitative Score	v3 + v4 + full	$8 + 15 + 8 = 23$	v3 hereda registro de v2; v4 y full no tienen GT a nivel de píxel
Qualitative Score	v4 + full	$15 + 8 = 23$	Sin GT a nivel de píxel para calificar

Camera Speed	full	8	Captura manual por gastroenterólogo, sin UR3e
Brightness	full	8	Idem
Deformation	full	8	Marcada inconsistentemente (encontrada como cadena vacía)

Tabla 5. Clasificación del missingness estructural.

Integridad referencial del pareo v2/v3

La afirmación del paper original, que cada video v3 reutiliza la trayectoria del robot del video v2 correspondiente, se verificó por nomenclatura, encontrando dos asimetrías en el dataset: c1_ascending_t1 tiene v2 pero no v3, y c2_transverse2_t4 tiene v3 pero no v2. Hay por tanto 56 pares completos.

Cardinalidad de variables categóricas

Variable categórica	Cardinalidad	Valores observados
Colon	2	c1, c2
Segment	10	ascending, cecum, descending, full, rectum, sigmoid, sigmoid1, sigmoid2, transverse1, transverse2
Segment Full (desambiguado)	17	c1_ascending, c1_cecum, ..., c2_sigmoid, c2_transverse2
Phantom Number	4	t1, t2, t3, t4
Video Number / vtype	4	v1, v2, v3, v4
Debris	2	no, yes
Deformation	3	(cadena vacía), no, yes
Open End Visible	2	no, yes
Qualitative Score	3	1.0, 2.0, 3.0

Tabla 6. Cardinalidad y valores observados de cada variable categórica.

Mapa de calor de valores nulos




Figura 18. Mapa de calor de valores nulos en los metadatos.

Etapa 2. Análisis univariado de metadatos

Sesgos y transformaciones

Se aplicó análisis de distribución a las variables numéricas (Camera Speed, Brightness, Edge Enhancement, Quantitative Score, Total Frames), con cálculo explícito del coeficiente de sesgo y recomendación automática de transformación. Los resultados son:

Variable	n	Media	σ	Skewness	Transformación
Camera Speed	169	17.99	10.18	+2.07	Requerida (log)
Camera Speed (log)	169	2.84	0.44	+0.67	Opcional
Brightness	169	0.80	3.33	+0.22	Ninguna
Edge Enhancement	177	2.55	0.61	-0.41	Ninguna
Quantitative Score	112	-0.02	0.98	-0.55	Opcional
Total Frames	177	921.95	2431.88	+4.53	Requerida (log)

Tabla 7. Coeficientes de sesgo y skewness

El hallazgo principal es que tanto Camera Speed (sesgo +2.07) como Total Frames (sesgo +4.53) presentan sesgo fuerte y se beneficiarían de transformación logarítmica. Brightness, Edge Enhancement y Quantitative Score se mantienen razonablemente simétricos sin transformación.

Distribución por segmento anatómico




Figura 19. Frecuencia de segmentos anatómicos. La desagregación por colon es necesaria porque el segmento 'sigmoid' de c2 es anatómicamente distinto a los segmentos 'sigmoid1' y 'sigmoid2' de c1.

Análisis multi-etiqueta de Tags




Figura 20. Distribución de tags y número de tags por video.




Figura 21. Matriz de co-ocurrencia de tags. La diagonal indica la frecuencia marginal de cada tag; las celdas fuera de la diagonal cuentan cuántos videos contienen ambos tags simultáneamente.

Las co-ocurrencias relevantes son: polyp aparece junto a la mayoría de los demás tags (es el tag más frecuente, $n=55$); textureless enfase ocurre frecuentemente con polyp (16) y water on lens (12); fast y zigzag co-ocurren en 6 videos (consistente con el hecho de que ambos describen movimiento no-suave).

Etapas 3. Análisis bivariado y multivariado

Matriz de correlación




Figura 22. Matriz de correlación de Spearman entre variables numéricas.

Únicamente una correlación resulta estadísticamente significativa: Camera Speed ↔ Total Frames con $\rho = -0.60$ ($p = 1.4 \times 10^{-17}$). Esta correlación negativa es consistente con la cinemática del experimento: velocidades mayores producen videos más cortos. El resto de las correlaciones permanecen en el rango $[-0.15, +0.15]$ y se interpretan como efectivamente nulas. En particular, Quantitative Score ↔ Total Frames es prácticamente cero, lo que indica que la calidad del registro 2D/3D no depende de la duración del video.

Validación cruzada del sistema de scoring




Figura 23. Validación monótona del scoring cualitativo mediante el scoring cuantitativo (panel izquierdo) y relación entre Camera Speed y score cualitativo (panel derecho).

Las medianas del score cuantitativo por categoría cualitativa siguen un patrón monótono: Score 1 $\rightarrow$ +0.62, Score 2 $\rightarrow$ -0.29, Score 3 $\rightarrow$ -1.01. Esta correspondencia es la evidencia más fuerte de que el sistema de doble scoring del paper (cualitativo manual + cuantitativo basado en Dice y Chamfer sobre mapas de bordes) es internamente consistente y puede tratarse como confiable para filtrar videos por calidad.

Distribución de scores por segmento anatómico




Figura 24. Conteo de videos por segmento anatómico x score

Tasa de fallo por escenario clínico (Tags)




Figura 25. Etiquetas (tags) x score cualitativo, mostradas como conteos absolutos (izquierda) y como tasas por fila normalizadas (derecha).

Tag	n	Score 1	Score 2	Score 3	Interpretación
-----	---	---------	---------	---------	----------------

debris on lens	5	80%	20%	0%	Bien tolerado
straight line	9	78%	0%	22%	Trayectoria simple, mayormente bien
mirrored path	8	62%	0%	38%	Re-visitación estresa al registro
fast	26	58%	23%	19%	Robusto pese a velocidad
zigzag	25	56%	28%	16%	Robusto
loop	21	29%	24%	48%	MAYOR tasa de fallo
water on lens	21	33%	24%	43%	Segundo más problemático
polyp	48	35%	25%	40%	Frecuente pero no el más problemático

Tabla 8. Tasa de fallo de registro por tag, ordenada por proporción en score 3 (descendente).

Hallazgo central de la Etapa 3: tras normalizar por la frecuencia marginal de cada tag, los escenarios con mayor tasa de fallo de registro son *loop* (48% en score 3) y *water on lens* (43%). El tag *polyp*, aunque aparece en 48 videos, presenta una tasa de fallo de 40%, similar a la media y menor que *loop*. Esto reorienta la interpretación: las trayectorias circulares (loops) y la presencia de agua en la lente son las condiciones que más estresan al algoritmo de registro 2D/3D, no la presencia de pólipos.

Etapa 4. Análisis cinemático intra-video

Marco metodológico

Esta etapa apunta a caracterizar la cinemática de la cámara dentro de cada video, utilizando los archivos `pose.txt`. Cada uno contiene una matriz 4×4 homogénea cámara-a-mundo aplanada en orden column-major, una por cuadro. El procesamiento recupera la traslación (X, Y, Z) por frame y, mediante `np.diff`, calcula la magnitud de desplazamiento entre cuadros consecutivos.

La intención original era procesar los `pose.txt` de los 169 videos registrados, pero el repositorio Johns Hopkins Dataverse devuel ve HTTP 403 al endpoint de listado de metadatos sin autenticación, y el proceso de creación de cuenta no pudo completarse en el plazo de este análisis. Como sustituto se ejecutó una muestra estratificada de 10 videos seleccionados programáticamente para cubrir los escenarios cinemáticos clave (*fast*, *loop*, *zigzag*, *straight line*, *exploratory*, *mirrored path*), más un par *v2/v3* para validar el pareo de trayectorias, controles limpios sin

tags, y un video v4 de deformación. De los 10 videos planeados, 9 archivos pose.txt fueron efectivamente descargados.

Resultados: comparativa de estabilidad cinemática




Figura 26. Magnitud de desplazamiento inter-frame para las 9 secuencias analizadas. Los identificadores V1–V9 corresponden a los archivos descargados secuencialmente.

La Figura 26 muestra una alta variabilidad inter-secuencia. V1 destaca con outliers extremos (hasta 6.5 unidades de desplazamiento), consistente con un video tageado como 'fast' o 'zigzag' del subconjunto descargado. V2 a V8 muestran distribuciones acotadas y similares entre sí (medianas en el rango 0.2-0.5), lo que sugiere trayectorias controladas y bien comportadas. V9 muestra desplazamiento moderado pero con cola más larga que el resto.

Para los algoritmos de tracking fotométrico, base de Endo-Depth-and-Motion, secuencias con perfil tipo V1 son potencialmente problemáticas: las ráfagas de desplazamiento por encima de un cierto umbral causan pérdida de seguimiento al violar el supuesto de movimiento pequeño entre frames. Para EndoGaussian y NExF, que reciben poses como input, la cinemática inter-frame no representa un riesgo de tracking pero sí condiciona la calidad de la inicialización gaussiana o de la representación volumétrica.

Mejoras

La muestra de 9 videos no permite caracterizar la distribución poblacional de la cinemática del dataset completo (169 videos registrados). Los resultados son válidos para inspección comparativa pero no estadísticamente representativos. Las

siguientes mejoras quedan pendientes para una iteración futura con acceso completo a la API:

- Análisis cuantitativo del pareo v2/v3: el dataset contiene 56 pares cuya identidad de trayectoria podría validarse calculando la diferencia frame-a-frame entre ambas trayectorias; debería ser sub-milimétrica dado que la repetibilidad del UR3e es ± 0.03 mm. Esta validación cuantitativa de una afirmación del paper original sería un hallazgo significativo en sí mismo.
- Con todos los pose.txt disponibles podría hacerse un test estadístico (Mann-Whitney) sobre si el tag 'fast' realmente corresponde a desplazamiento medio superior, si 'loop' implica retornar al punto inicial, etc. Este es el contra-test riguroso de las anotaciones provistas por los autores.
- Distribución cinemática estratificada por segmento anatómico: para identificar si ciertos segmentos (e.g., sigmoid con su curvatura) presentan trayectorias sistemáticamente distintas a otros.
- Análisis de rotación 6-DoF: únicamente se analizaron las traslaciones; un análisis de rotaciones entre frames consecutivos completaría la caracterización 6-DoF y permitiría distinguir entre videos con movimiento puramente lineal versus orbital, lo cual tiene implicaciones distintas para NeRF (que necesita variedad angular) frente a 3D Gaussian Splatting (más tolerante).

Etapa 5. Análisis multimodal a nivel de píxel

Para examinar las modalidades de ground truth disponibles en cada video registrado (RGB, depth, normals, occlusion, optical flow, diffuse), se descargó y descomprimió un único segmento del dataset: c1_sigmoid1_t2_v2. Sobre este segmento se procesaron 3 cuadros de muestra (frames 0000, 0001, 0002) inspeccionando simultáneamente las tres modalidades principales.




Figura 27. Análisis multimodal de un frame de muestra: RGB original (col 1), mapa de profundidad en milímetros (col 2), distribución absoluta de profundidad (col 3), y vectores normales (col 4).

Hallazgos a nivel de imagen:

El brillo medio del frame analizado es 161.1 sobre 255, indicativo de exposición razonable; la imagen no está ni saturada ni sub-expuesta de forma sistemática.

La profundidad sigue una distribución asimétrica con concentración entre 10–30 mm (campo cercano: paredes laterales y haustras próximas) y una cola larga hacia 80 mm (campo lejano: lumen profundo).

Los vectores normales codifican direcciones tridimensionales del relieve mucoso (canales R, G, B mapeando a X, Y, Z respectivamente, escalados de ± 1 a 0–65535); la coloración varía suavemente según la orientación local de la superficie.

La síntesis automática reporta desviación estándar inter-frame del brillo de 0.0 (con sólo 3 frames). Esto sugiere iluminación estable a corto plazo, pero el cálculo no es informativo con tan pocas muestras.

Mejoras

El análisis se ejecutó sobre un único segmento (c1_sigmoid1_t2_v2) y sólo 3 frames. La pregunta del pipeline “¿se deben normalizar las imágenes para visualización?” no puede responderse responsablemente con esta muestra, ya que su respuesta depende de la variabilidad inter-video del brillo y del contraste, dimensión que esta Etapa 5 no exploró. Las siguientes son mejoras necesarias a aplicar previo al inicio de la siguiente etapa del proyecto:

- Muestreo inter-video del brillo y la saturación, sobre 5-10 frames de cada uno de los 9 videos del Stage 4 ya descargados o sobre una muestra estratificada de ~30 videos. Esto permitiría caracterizar la distribución de brillo entre videos y dar una recomendación informada sobre normalización.
- Análisis de reflexiones especulares: los píxeles saturados (ceranos al máximo de RGB) introducen un sesgo conocido en algoritmos de matching fotométrico. Su frecuencia y localización debería cuantificarse, especialmente cruzando con el tag 'saturation' presente en 22 videos del dataset.
- Análisis de máscara de viñeteo (fisheye): la cámara colonoscópica produce esquinas negras debido al lente fisheye. Estos píxeles deben enmascarse explícitamente para no contaminar las estadísticas de profundidad ni el cálculo del loss durante el entrenamiento. La construcción y validación de esta máscara debería formar parte de una iteración futura.

Verificación cruzada de las modalidades: confirmar mediante muestreo aleatorio que las dimensiones (1350×1080) y la codificación documentada (depth en uint16 con escala 0–100 mm; normals con canales mapeando a ± 1 ; etc.) se mantienen consistentes a lo largo de todos los videos. El paper documenta la codificación pero no garantiza su uniformidad.

Etapa 6. Sesgo espacial y balance de la variable objetivo

Esta etapa cuantifica el desbalance de clases en el espacio de profundidad, que es la variable objetivo del problema de estimación de profundidad monocular. Sobre 10 cuadros de profundidad del mismo segmento c1_sigmoid1_t2_v2 (un total de 13,559,510 píxeles útiles tras enmascarar los píxeles inválidos con valor 0), se calculó la proporción de píxeles que caen en tres rangos absolutos de distancia:




Figura 28. Distribución de profundidad absoluta sobre 10 frames de muestra, con enmascaramiento del viñeteo fisheye.

La distribución resultante es:

Cerca (0–20 mm): 32.7% de los píxeles útiles

Medio (20–50 mm): 51.6% de los píxeles útiles

Lejos (50–100 mm): 15.7% de los píxeles útiles

El campo medio domina (~52%), seguido del campo cercano (~33%), con el campo lejano sub-representado (~16%). Esta distribución contradice la hipótesis ingenua de que la mayoría de los píxeles estarían en el campo cercano. La razón es geométrica: en una vista interna del lumen colónico, las paredes laterales próximas ocupan una banda relativamente delgada de la imagen, mientras que el cuerpo del lumen, visible hacia adelante en profundidad media, ocupa la mayoría del área.

La implicación práctica para los métodos a comparar: una función de pérdida uniforme en píxeles asignará un peso aproximadamente 3× mayor al campo medio que al campo lejano. Esto resultará, salvo intervención, en modelos que aprenden

bien las paredes medias del colon pero subestiman sistemáticamente la profundidad real cuando la cámara observa el lumen profundo. Una pérdida espacialmente balanceada (e.g., pesar el campo lejano para corregir su menor representación) es la mitigación estándar.

Mejoras

Este resultado se obtuvo de 10 frames de un único video. La distribución 33/52/16 reportada en este informe es indicativa, no representativa del dataset completo. Los puntos para una iteración con muestra completa son:

- Muestreo estratificado por segmento anatómico: el balance de profundidad probablemente difiere entre cecum (campo lejano dominante por la geometría del fondo de saco), ascending colon (vista frontal del lumen, campo medio dominante) y rectum (transición con campo lejano hacia afuera). Hacer el análisis por separado para cada segmento revelaría sesgos diferenciales.
- Comparación entre videos v2 (limpios) y v3 (con debris): el debris ocluye porciones del campo lejano, lo que probablemente sesga el balance de profundidad hacia el campo cercano en v3. Esta diferencia, si se cuantifica, justifica entrenar o evaluar por separado.
- Análisis de profundidad por trayectoria: videos con el tag 'textureless enface' acercan la cámara perpendicularmente a una pared, lo que sesga severamente la distribución de profundidad hacia el campo cercano. Identificar qué proporción del dataset tiene este patrón es clave para diseñar el split de entrenamiento.
- Validación con la coverage_mesh.obj: el archivo coverage_mesh.obj documenta qué partes del modelo 3D están efectivamente observadas por la trayectoria del video. Esta información puede usarse como ground truth de referencia para verificar el cálculo de balance espacial.

Etapas 7: Síntesis y recomendaciones para el modelado

En esta sección discutiremos los resultados obtenidos en cada etapa, distinguiendo entre hallazgos firmes (con evidencia cuantitativa de las etapas 1 a 3) y hallazgos preliminares (con evidencia parcial de las etapas 4 a 6). Se enmarca todo en términos del objetivo del proyecto: comparar Endo-Depth-and-Motion, EndoGaussian y Neural Exposure Fields sobre C3VDv2.

Estado de las etapas y cobertura del pipeline

Etapas	Cobertura	Estado	Limitación principal
--------	-----------	--------	----------------------

1	Integridad + missingness + cardinalidad	Completa	Validación referencial encontró 2 asimetrías v2/v3
2	Univariado + sesgo + transformaciones	Completa	Ninguna importante
3	Bivariado + correlación + tags×score	Completa	Ninguna importante
4	Cinemática multi-secuencia	Parcial (n=9)	Sin acceso API; muestra estratificada en lugar de las 169 trayectorias
5	Multimodal a nivel de píxel	Parcial (1 video, 3 frames)	Sólo un segmento (c1_sigmoid1_t2_v2); no se evaluó estabilidad inter-video
6	Sesgo espacial + balance objetivo	Parcial (10 frames de 1 video)	Misma limitación de Etapa 5; resultados extrapolables sólo cualitativamente
7	Síntesis + recomendaciones	Reescrita en este informe	—

Tabla 9. Estado de cobertura y limitación principal por etapa.

Calidad de los metadatos

El dataset C3VDv2 presenta una estructura limpia y bien documentada. La totalidad del missingness observado (Quantitative Score en 23 filas, Qualitative Score en 23 filas, Camera Speed/Brightness en 8 filas) es estructural y explicable por el diseño del dataset: los videos v3 heredan registro de v2; los videos v4 y full carecen de ground truth a nivel de píxel; los videos full se capturan manualmente sin configuración del UR3e. No se detectaron anomalías de missingness que requieran imputación.

Existen 56 pares completos v2/v3 (no 57), con dos asimetrías: c1_ascending_t1 sin pareja v3 y c2_transverse2_t4 sin pareja v2. Cualquier análisis pareado debe filtrar por la intersección de v2 y v3.

Variables por transformar

Camera Speed (sesgo +2.07) y Total Frames (sesgo +4.53) requieren transformación logarítmica antes de su uso como features o targets en cualquier modelo tabular o estadístico. La transformación log reduce el sesgo de Camera Speed a +0.67 y de Total Frames a +2.50 (todavía moderado). Brightness, Edge Enhancement y Quantitative Score no requieren transformación.

Validación del sistema de scoring del paper

La correlación monótonica entre Qualitative Score (manual) y Quantitative Score (Dice + Chamfer sobre mapas de bordes) confirma que el doble sistema de scoring

del paper es internamente consistente. Las medianas son: Score 1 $\rightarrow$ +0.62, Score 2 $\rightarrow$ -0.29, Score 3 $\rightarrow$ -1.01. Este resultado autoriza el uso del Qualitative Score como filtro fiable de calidad.

Tags con mayor tasa de fallo de registro

Tras normalización por frecuencia marginal de cada tag, los escenarios más estresantes para el algoritmo de registro son loop (48% en score 3), water on lens (43%) y polyp (40%). El tag fast, contrariamente a la intuición inicial, no es problemático (sólo 19% en score 3); las trayectorias circulares (loops, mirrored path) y los obstáculos sobre la lente son las verdaderas dificultades.

Estabilidad cinemática

Sobre 9 secuencias analizadas, la mayoría presenta desplazamiento inter-frame controlado (mediana 0.2–0.5 unidades de longitud) con outliers ocasionales. Una secuencia (V1) presenta ráfagas extremas con outliers hasta 6.5, consistente con escenarios tipo 'fast' o 'zigzag'. Estos picos representan un riesgo concreto para los métodos de seguimiento fotométrico (Endo-Depth-and-Motion), no así para los métodos que reciben poses como input (EndoGaussian, NExF). La caracterización completa requeriría las 169 trayectorias del dataset.

Codificación del ground truth

El mapa de profundidad está codificado como entero de 16 bits con escala lineal 0–100 mm; en el frame de muestra inspeccionado, el rango efectivo fue 0 a 88.1 mm. Los vectores normales utilizan tres canales 16-bit codificando los componentes (X, Y, Z) de la dirección normal, escalados de ± 1 a 0–65535. Las máscaras de oclusión son binarias (255 = ocluido) en 8 bits. Estas codificaciones deben respetarse al cargar los archivos.

Balance de la variable objetivo

La distribución de profundidad observada en una muestra de 10 frames es aproximadamente 33% cerca (0–20 mm) / 52% medio (20–50 mm) / 16% lejos (50–100 mm). El campo lejano es el menos representado. Este balance debe validarse sobre una muestra estratificada por segmento anatómico antes de informar el diseño de la función de pérdida.

Sobre la división de datos (train / validation / test)

La estratificación debe realizarse a nivel de trayectoria, no a nivel de frame, para evitar fuga de información (frames cercanos comparten contenido casi idéntico). Adicionalmente:

- Mantener los pares v2/v3 juntos en el mismo Split: un modelo no debe ver el v2 en entrenamiento y el v3 en test (o viceversa), porque la trayectoria es idéntica.
- Estratificar por (colon, segment, texture) para asegurar que las cuatro variantes de phantom estén representadas en cada split.
- Asignar los videos Score 3 al conjunto de stress-test exclusivamente; usarlos en entrenamiento contamina el target con artefactos de registro. Los videos Score 1 y 2 son el conjunto de entrenamiento confiable.
- Reservar los videos v4 (deformación) como conjunto cualitativo separado: EndoGaussian es el único de los tres métodos con un módulo explícito de deformación.

Función de pérdida

Dado el desbalance espacial preliminarmente detectado (campo lejano sub-representado), se recomienda una función de pérdida espacialmente balanceada para los métodos basados en regresión directa (Endo-Depth-and-Motion). Para los métodos basados en renderizado (EndoGaussian, NExF) el balance se gestiona naturalmente a través del proceso de rasterización, pero el efecto residual debe verificarse comparando métricas por banda de profundidad.

Modelo de cámara

Las intrínsecas son del modelo omnidireccional esférico de Scaramuzza, no del modelo pinhole estándar. El paper documenta los polinomios α_0 - α_4 y los parámetros de stretch/center shift en camera_intrinsics.txt. Cualquier implementación que asuma proyección pinhole introducirá errores sistemáticos. Los tres métodos deben configurarse con soporte fisheye/omnidireccional.

Nomenclatura

La columna Tags requiere normalización pre-procesamiento (eliminación de dobles espacios, corrección 'zizag' → 'zigzag') si se va a usar como criterio de filtrado. La columna Segment de Colon 2 contiene un 'sigmoid' que es anatómicamente distinto a 'sigmoid1' y 'sigmoid2' de Colon 1.

Afirmaciones del paper referente al dataset aún por validar

Dos afirmaciones del paper original quedan por validar cuantitativamente en una iteración futura: (i) que las trayectorias v2 y v3 son idénticas dentro de la repetibilidad del UR3e (± 0.03 mm), y (ii) que los tags anotados ('fast', 'zigzag', 'loop', etc.) corresponden a propiedades cinemáticas medibles. Ambas validaciones requieren acceso a los 169 pose.txt registrados.

Risk register y metodología de aseguramiento de calidad (CRISP-ML(Q))

Esta sección consolida los riesgos identificados a lo largo de las siete etapas del EDA y propone medidas de aseguramiento de calidad para la fase de modelado.

ID	Riesgo	Origen (etapa)	Severidad	Probabilidad	Estrategia de mitigación
R1	Fuga de información entre conjuntos de entrenamiento y prueba por pares v2/v3 con trayectoria idéntica	Etapa 1	Alta	Cierta si no se mitiga	Mantener pares v2/v3 en el mismo split mediante estratificación a nivel de trayectoria, no de frame
R2	Inyección de ruido al entrenamiento por uso de videos con score cualitativo 3	Etapa 3	Alta	Cierta si no se mitiga	Excluir score 3 del conjunto de entrenamiento; reservar como stress-test exclusivamente
R3	Errores sistemáticos por asumir modelo de cámara pinhole en lugar del modelo omnidireccional de Scaramuzza	Etapa 7	Alta	Cierta si no se mitiga	Configurar los tres métodos con soporte fisheye/omnidireccional desde la implementación
R4	Función de pérdida mal calibrada por desconocimiento del balance espacial real inter-segmento	Etapa 6	Media-Alta	Probable	Re-ejecutar Etapa 6 sobre muestra estratificada por (colon, segment) antes de fijar la función de pérdida
R5	Decisión incorrecta sobre normalización RGB por desconocimiento de la variabilidad inter-video de iluminación	Etapa 5	Media	Probable	Muestreo inter-video del brillo sobre ~30 videos antes de fijar la estrategia de normalización
R6	Pérdida de tracking en Endo-Depth-and-Motion sobre secuencias con ráfagas cinemáticas extremas	Etapa 4	Media	Probable en escenarios fast/zigzag	Reportar métricas estratificadas por escenario; documentar fallos esperados
R7	Inconsistencia en la codificación de modalidades ground truth entre videos	Etapa 5	Media	Baja-media	Verificación cruzada por muestreo aleatorio antes del entrenamiento
R8	Anotaciones de tags no validadas empíricamente (texto vs cinemática medible)	Etapa 4	Baja-Media	Desconocida	Test estadístico (Mann-Whitney) sobre las trayectorias completas en iteración futura

R9	Sesgo de evaluación por sub-representación de videos v4 (deformación)	Etapas 1	Baja	Cierta	Reservar v4 como conjunto cualitativo separado; sólo EndoGaussian se evalúa allí
R10	Inconsistencias documentales menores (cadena vacía en Deformation, tipografía 'zizag')	Etapas 1	Baja	Cierta	Higiene de cadenas obligatoria como primer paso de cualquier pipeline de carga

Tabla 10. Registro de riesgos identificados durante la fase de Data Understanding del dataset C3VDv2.

Conclusiones

Elda Cristina Morales Sánchez de la Barquera -



“En este avance confirmé que el análisis de datos endoscópicos exige una lógica distinta a la de los datos tabulares tradicionales. Trabajar con HAMLYN me permitió comprender mejor la importancia de revisar primero la estructura, la calidad y la trazabilidad de los archivos antes de pensar en cualquier modelo predictivo. Considero que el uso de la versión rectificada fue una decisión metodológica adecuada, porque facilitó el análisis

de pares estéreo y mapas de profundidad sin perder el enfoque técnico del proyecto. También me pareció relevante identificar que no todas las secuencias tienen la misma calidad geométrica, aun cuando pertenezcan al mismo dataset. Esto refuerza la necesidad de aplicar normalización, filtrado y control por secuencia antes del entrenamiento. Desde mi perspectiva, HAMLYN complementa muy bien a SCARED porque aporta mayor realismo quirúrgico y variabilidad visual. Además, este avance fortaleció la reproducibilidad del proyecto al documentar el análisis en GitHub mediante notebooks, tablas y figuras. En conjunto, considero que esta etapa permitió pasar de una simple descarga de datos a una comprensión más rigurosa de su utilidad para visión computacional médica.”

María Paula Gutiérrez Cervantes -



"Este avance fue una curva de aprendizaje empinada pero muy interesante. Entender la profundidad y estructura tomó tiempo, hubo errores y hallazgos durante el camino, pero cada uno de ellos me obligó a regresar y revisar conceptos nuevos. A partir de este análisis pude comprender mejor que el procesamiento de datos endoscópicos exige una lógica técnica que trasciende el análisis tabular tradicional, integrando secuencias de videos, mapas métricos, etc. Los hallazgos encontrados durante esta etapa serán fundamentales para la siguiente etapa, en conjunto, nos servirán para que la ingeniería de características no se base en suposiciones teóricas, sino en una caracterización empírica y rigurosa que vincula la textura visual con la realidad física de un entorno tan retador como el entorno médico".

José Manuel Toral Cruz



"Los datos de SCARED representan un reto poco convencional: no son tabulares, no son planos y no se distribuyen en un sólo tipo de archivo. Además de que su tamaño exige un control del proceso de ingesta y de consumo bastante elevado. Aunado a lo anterior, el sólo hecho de entender su estructura permite entender el potencial del dataset para estimar modelos. Otro descubrimiento interesante es el conjunto de métricas necesarias ya no sólo para evaluar un modelo relativamente decente, sino para diagnosticar la calidad de la imagen y anticiparnos a problemas en las tomas. El siguiente paso de ingeniería de características va a poner a prueba el entendimiento de estos diagnóstico."

Referencias

- Atmis, M., Karacan, L., & Sarigul, M. (2025). One-step specular highlight removal with adapted diffusion models. En *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)* (pp. 455-468). https://openaccess.thecvf.com/content/ICCV2025/papers/Atmis_One-Step_Specular_Highlight_Removal_with_Adapted_Diffusion_Models_ICCV_2025_paper.pdf
- Borgli, H., Thambawita, V., Smedsrud, P. H., et al. (2020). HyperKvasir, a comprehensive multi-class image and video dataset for gastrointestinal endoscopy. *Scientific Data*, 7(1), Artículo 283. <https://doi.org/10.1038/s41597-020-00622-y>
- Don, S. (2023). Computer-aided diagnosis of polyp classification using scale invariant features and extreme gradient boosting. *Journal of Medical Physics*, 48(3), 230-237. https://doi.org/10.4103/jmp.jmp_29_23
- Elhelw, M. A., Nicolaou, M., Chung, A., & Yang, G. Z. (2006). Photorealistic modeling of tissue reflectance properties. *Computer Aided Surgery*, 11(6), 289-299. <https://doi.org/10.3109/10929080601022915>
- Emaduddin, M., Halic, T., Demirel, D., Bayrak, C., Arikatla, V. S., & De, S. (2023). Specular reflection removal for 3D reconstruction of tissues using endoscopy videos. En 2023 *IEEE SoutheastCon* (pp. 246-252). <https://doi.org/10.1109/southeastcon51012.2023.10115137>
- Espinosa, R., Ochoa-Ruiz, G., & Daul, C. (2025). *Transformer-based illumination invariant self-supervised monocular depth estimation in endoscopy*. SSRN. <https://doi.org/10.2139/ssrn.5189985>
- Garcia-Vega, A., Espinosa, R., Ramirez-Guzman, L., Bazin, T., Falcon-Morales, L., Ochoa-Ruiz, G., Lamarque, D., & Daul, C. (2022). *Multi-scale structural-aware exposure correction for endoscopic imaging*. arXiv. <https://arxiv.org/pdf/2210.15033>
- Golhar, M. V., Fretes, L. S. G., Ayers, L., Akshintala, V. S., Bobrow, T. L., & Durr, N. J. (2025). *C3VDv2 – Colonoscopy 3D video dataset with enhanced realism*. arXiv. <https://arxiv.org/abs/2506.24074>

- Hamlyn Centre for Robotic Surgery. (n.d.). *Hamlyn endoscopic / laparoscopic video datasets*. Imperial College London. Retrieved May 9, 2026, from <https://hamlyn.doc.ic.ac.uk/vision/>
- Joseph, J., George, S. N., & Raja, K. (2023). Parameter-free matrix decomposition for specular reflections removal in endoscopic images. *IEEE Journal of Translational Engineering in Health and Medicine*, 11, 360-374. <https://doi.org/10.1109/JTEHM.2023.3283444>
- Li, F., Ma, J., Liang, H., Tian, Z., Wu, Z., Wen, T., & Liu, D. (2025). A comprehensive survey of specularity detection: State-of-the-art techniques and breakthroughs. *IEEE Access*.
- Li, W., Jia, F., & Liu, W. (2024). EndoSRR: A comprehensive multi-stage approach for endoscopic specular reflection removal. *International Journal of Computer Assisted Radiology and Surgery*, 19(6), 1203-1211. <https://doi.org/10.1007/s11548-024-03137-8>
- Liu, S., Fan, J., Ai, D., Song, H., Fu, T., Wang, Y., & Yang, J. (2022). Feature matching for texture-less endoscopy images via superpixel vector field consistency. *Biomedical Optics Express*, 13(4), 2247-2265. <https://doi.org/10.1364/BOE.450259>
- Madessa, A. H., Dong, J., Gan, Y., & Gao, F. (2023). A deep learning approach for specular highlight removal from transmissive materials. *Expert Systems*, 40(2), Artículo e12598. <https://onlinelibrary.wiley.com/doi/abs/10.1111/exsy.12598>
- Marcinczak, J. M., & Grigat, R. R. (2013). Closed contour specular reflection segmentation in laparoscopic images. *International Journal of Biomedical Imaging*, 2013, Artículo 593183. <https://doi.org/10.1155/2013/593183>
- maxhallan7. (2024). *scared* [Dataset]. Hugging Face. <https://huggingface.co/datasets/maxhallan7/scared>
- Nie, C., Xu, C., Li, Z., Chu, L., & Hu, Y. (2023). Specular reflections detection and removal for endoscopic images based on brightness classification. *Sensors*, 23(2), Artículo 974. <https://doi.org/10.3390/s23020974>
- OpenAI. (2026). *Diagrama de reflectancia no lambertiana* [Imagen generada por IA]. ChatGPT.

- Ou, M., Li, H., Zhang, Y., Niu, K., Qiu, Z., Li, H., & Liu, J. (2025). *DeLightMono: Enhancing self-supervised monocular depth estimation in endoscopy by decoupling uneven illumination*. arXiv. <https://arxiv.org/abs/2511.20058>
- Recasens, D., Lamarca, J., Fácil, J. M., Montiel, J. M. M., & Civera, J. (2021). *Endo-Depth-and-Motion: Reconstruction and tracking in endoscopic videos using depth networks and photometric constraints*. arXiv. <https://arxiv.org/abs/2103.16525>
- Sánchez, F. J., Bernal, J., Sánchez-Montes, C., Miguel, C. R., & Fernández-Esparrach, G. (2017). Bright spot regions segmentation and classification for specular highlights detection in colonoscopy videos. *Machine Vision and Applications*, 28(8), 917–936. <https://doi.org/10.1007/s00138-017-0864-0>
- Shao, S., Pei, Z., Chen, W., Zhu, W., Wu, X., Sun, D., & Zhang, B. (2022). Self-supervised monocular depth and ego-motion estimation in endoscopy: Appearance flow to the rescue. *Medical Image Analysis*, 77, Artículo 102338. <https://doi.org/10.1016/j.media.2021.102338>
- Teevno, M. A., Martinez-Garcia-Peña, R., Ochoa-Ruiz, G., & Ali, S. (2024). *Domain generalization for endoscopic image segmentation by disentangling style-content information and superpixel consistency*. arXiv. <https://arxiv.org/html/2409.12450v1>
- Teevno, M. A., Ochoa-Ruiz, G., & Ali, S. (2024). *Tackling domain generalization for out-of-distribution endoscopic imaging*. arXiv. <https://arxiv.org/abs/2410.14821>
- UZ-SLAMLab. (n.d.). *Endo-Depth-and-Motion: Localization and reconstruction in endoscopic videos using depth networks and photometric constraints* [Computer software]. GitHub. Retrieved May 9, 2026, from <https://github.com/UZ-SLAMLab/Endo-Depth-and-Motion>
- VSLAM-LAB. (n.d.). *Hamlyn Rectified Dataset* [Data set]. Hugging Face. Retrieved May 9, 2026, from https://huggingface.co/datasets/vslamlab/Hamlyn_Rectified_Dataset
- Xu, G., Xu, S., Lu, S., Liu, Y., Yang, B., Lyu, J., & Zheng, W. (2025). Encoder-guided latent space search based on generative networks for stereo disparity estimation in

- surgical imaging. *Computer Modeling in Engineering and Sciences*, 145(3), 4037-4053. <https://doi.org/10.32604/cmes.2025.074901>
- Yin, H., Eimen, R., Moyer, D., & Bowden, A. K. (2024). SpecReFlow: An algorithm for specular reflection restoration using flow-guided video completion. *Journal of Medical Imaging*, 11(2), Artículo 024012. <https://doi.org/10.1117/1.JMI.11.2.024012>
- Yin, T. K., Huang, K. L., Chiu, S. R., Yang, Y. Q., & Chang, B. R. (2022). Endoscopy artefact detection by deep transfer learning of baseline models. *Journal of Digital Imaging*, 35(5), 1101-1110. <https://doi.org/10.1007/s10278-022-00627-6>
- Yu, B., Chen, W., Zhong, Q., & Zhang, H. (2021). Specular highlight detection based on color distribution for endoscopic images. *Frontiers in Physics*, 8, Artículo 616930. <https://doi.org/10.3389/fphy.2020.616930>
- Yu, Z., Du, C., Liang, H., Zheng, X., Ma, Z., Wu, M., Ao, M., & Lao, Q. (2025). Endoscopic artifact inpainting for improved endoscopic image segmentation. En *Medical Image Computing and Computer Assisted Intervention – MICCAI 2025* (pp. 191–201). Springer. https://doi.org/10.1007/978-3-032-05127-1_19
- Zhang, Q., & Zeng, Y. (2026). VDTAR-Net: A cooperative dual-path convolutional neural network–transformer network for robust highlight reflection segmentation. *Computers*, 15(3), Artículo 168. <https://doi.org/10.3390/computers15030168>
- Zheng, X., Xie, R., Yao, X., et al. (2024). A generative adversarial network for multiple reads reconstruction in DNA storage. *Scientific Reports*, 14, Artículo 32071. <https://doi.org/10.1038/s41598-024-83806-5>
- Zheng, Y., Yan, Y., & Jiang, H. (2024). Semi-TSGAN: Semi-supervised learning for highlight removal based on teacher-student generative adversarial network. *Sensors*, 24(10), <https://doi.org/10.3390/s24103090>