

Instituto Tecnológico y de Estudios Superiores de Monterrey

Maestría en Inteligencia Artificial Aplicada

Proyecto Integrador

TC5035.10

Semana 4

Avance 2. Ingeniería de características

Equipo 52:

MNA A00449074 - Elda Cristina Morales Sánchez de la Barquera

MNA A01747706 - María Paula Gutiérrez Cervantes

MNA A01122243 - José Manuel Toral Cruz

Equipo docente:

Dra. Grettel Barceló Alonso – Profesora Titular

Dr. Luis Eduardo Falcón Morales – Profesor Titular

Mtra. Verónica Sandra Guzmán de Valle – Profesora Asistente

Patrocinador:

Dr. Gerardo Camacho

17 de mayo de 2026

Contenido

Introducción	3
1. Contexto metodológico del avance	3
2. Construcción de características	5
3. Normalización y transformaciones	7
4. Selección y extracción de características	8
4.1 Relación con modelos posteriores	9
5. Repositorio de GitHub y artefactos generados	10
6. Conclusiones	10
Conclusiones	11
Referencias	13



Introducción

El presente avance desarrolla la fase de ingeniería de características del proyecto “La luz que opaca: detección y supresión de reflejos especulares en imágenes endoscópicas”. Esta fase se ubica dentro de la preparación de datos de CRISP-ML(Q), por lo que su propósito no es entrenar aún los modelos de profundidad, sino transformar datos visuales complejos en insumos controlados, trazables y técnicamente justificables para el modelado posterior.

El conjunto de datos utilizado corresponde a SCARED (Structured light endoscopy And Reconstructed Depth), un benchmark de endoscopia quirúrgica diseñado para estimación de correspondencia estéreo, reconstrucción 3D y profundidad densa (Allan et al., 2021). En el notebook se trabajó con 20 keyframes distribuidos en cuatro datasets: dataset_1 y dataset_2 para entrenamiento, y dataset_8 y dataset_9 para prueba. Esta separación es relevante porque permite evaluar la generalización entre sujetos biológicos distintos, no únicamente la memorización de escenas similares.

La naturaleza del problema exige una preparación cuidadosa: las imágenes endoscópicas presentan reflejos especulares, iluminación no uniforme, zonas con baja textura, viñeteado y mapas de profundidad incompletos. Estas condiciones afectan tanto la calidad de los píxeles RGB como la disponibilidad del ground truth de profundidad. Por ello, el avance construye una representación tabular derivada por keyframe y define un pipeline tensorial que podrá reutilizarse en los modelos NeXF, EndoGaussian y EndoDepthAndMotion.


Contexto metodológico del avance

La ingeniería de características parte de una premisa central: SCARED no es un dataset tabular en su forma original. Cada observación integra una imagen RGB, un mapa de profundidad en formato TIFF, una nube de puntos en OBJ y, en ciertos casos, un video RGB asociado. Para analizar estadísticamente la calidad del dato, se construyó una tabla derivada donde cada fila representa un keyframe y cada columna captura una propiedad cuantitativa de la imagen, del mapa de profundidad o de la geometría 3D.

En términos de CRISP-ML(Q), esta etapa corresponde a la preparación de datos con aseguramiento de calidad. La decisión metodológica es importante porque evita que el proyecto avance directamente hacia el entrenamiento sin documentar antes los sesgos de iluminación, la proporción de ground truth válido, la severidad de los reflejos especulares y la posible redundancia entre variables. Este enfoque es consistente con la lógica de CRISP-ML(Q), que enfatiza la identificación temprana de riesgos técnicos y de calidad antes de modelar (Studer et al., 2021).

El avance también separa dos tipos de artefactos: por un lado, un dataframe de diagnóstico de 20 observaciones por 24 variables aproximadamente; por otro, un pipeline de preprocesamiento que opera sobre tensores de imagen y profundidad. Esta separación evita confundir las features de diagnóstico con las entradas finales de los modelos profundos. Las primeras permiten tomar decisiones informadas; las segundas serán usadas en la fase de entrenamiento y evaluación.

Figura 1. Pipeline del Proyecto



Nota. Ilustración conceptual elaborada con asistencia de inteligencia artificial generativa (OpenAI, ChatGPT/DALL·E), basada en el dataset SCARED y en modelos de estimación monocular de profundidad utilizados en visión computacional médica. La figura resume el flujo experimental de reconstrucción geométrica, comparación con nube de puntos OBJ y evaluación mediante métricas como AbsRel, RMSE y Chamfer Distance.

Tabla 1. SIPOC del proceso de ingeniería de características.

Elemento	Descripción
Suppliers	Dataset SCARED, sensor da Vinci con luz estructurada, archivos de calibración YAML y repositorio del proyecto.
Inputs	Left _Image.png, left_depth_map.tiff, point_cloud.obj y data/rgb.mp4 cuando está disponible.
Process	Extracción de features por keyframe, derivación de indicadores, corrección preliminar de especulares, cap de profundidad, transformación logarítmica, normalización, correlación, varianza y PCA.
Outputs	Dataframe de diagnóstico, features seleccionadas, indicadores de calidad, pipeline tensorial y artefactos de visualización.
Customers	Fase de entrenamiento y evaluación de NeXF, EndoGaussian y EndoDepthAndMotion en el Avance 3.

Construcción de características

La construcción de características responde al primer criterio de la rúbrica: crear variables nuevas y significativas a partir de las existentes, justificando cada decisión de procesamiento. En este avance, las variables no se limitaron a describir la imagen de forma superficial; se diseñaron para capturar condiciones que afectan directamente la estimación de profundidad endoscópica: saturación especular, cobertura del ground truth, distribución de profundidad, nitidez, luminancia, viñeteado, estabilidad temporal y geometría 3D.

Desde el canal Z del TIFF se extrajeron medidas de profundidad válidas: mediana, percentiles 5 y 95, rango y porcentaje de píxeles válidos. Estas variables permiten conocer si cada keyframe contiene información de profundidad suficiente para entrenar o evaluar un modelo. En el notebook se identificó que existen keyframes entre 13% y 28% de píxeles inválidos, lo cual obliga a interpretar las métricas de error únicamente sobre las zonas con ground truth disponible.

Desde las imágenes RGB se calcularon medidas de luminancia, dispersión, saturación y nitidez. La luminancia se obtuvo mediante la ponderación clásica $Y = 0.299R + 0.587G + 0.114B$ (Gonzalez & Woods, 2018), que permite resumir los tres canales de color en una señal relacionada con brillo percibido. El porcentaje de píxeles saturados, `sat_pct`, se definió como una variable crítica porque los reflejos especulares aparecen como regiones de alta intensidad donde se pierde información estructural del tejido (Yu et al., 2021). La varianza del Laplaciano, `laplacian_var`, se usó como aproximación a la nitidez y a la riqueza de textura local, relevante en un dominio donde la baja textura dificulta la correspondencia y la reconstrucción.

Cabe destacar que el cálculo estadístico de las métricas fotométricas (como `lum_mean` y `sat_pct`) se restringió estrictamente al área interior de la máscara

anatómica válida. Computar estos valores sobre la matriz rectangular completa habría sesgado los promedios artificialmente a la baja debido a los bordes negros (viñeteado) inherentes a la óptica del lente da Vinci. Esta exclusión garantiza que la varianza y la luminancia reportadas pertenezcan exclusivamente al tejido biológico.

También se construyeron variables derivadas, como `rb_balance`, `texture_depth_ratio` y `lum_contrast_ratio`. Estas variables integran relaciones entre color, textura, profundidad y contraste, por lo que aportan información más interpretable que los valores crudos. Además, el avance incorporó `vignette_score` para cuantificar la cobertura del ground truth en la región central y `inpaint_ssim` para estimar cuánto cambia la imagen después de suprimir reflejos especulares mediante inpainting. Esta última variable permite distinguir entre especulares localizados, donde el SSIM se mantiene alto, y especulares extensos, donde la corrección modifica de forma más sustantiva la estructura visual.

Tabla 2. Principales características construidas y justificación técnica.

Grupo	Características	Fuente	Justificación
Profundidad	<code>depth_median</code> , <code>depth_p5</code> , <code>depth_p95</code> , <code>depth_range</code> , <code>depth_valid_pct</code>	TIFF canal Z	Miden distribución, rango y completitud del ground truth de profundidad.
Luminancia y color	<code>lum_mean</code> , <code>lum_std</code> , <code>r_mean</code> , <code>g_mean</code> , <code>b_mean</code> , <code>rb_balance</code>	Imagen RGB	Describen brillo, dispersión y balance cromático del tejido observado.
Especularidad	<code>sat_pct</code> , <code>inpaint_ssim</code>	RGB + supresión de especulares	Cuantifican píxeles saturados y grado de alteración tras inpainting.
Textura	<code>laplacian_var</code> , <code>texture_depth_ratio</code>	RGB + profundidad	Aproximan nitidez y detalle relativo a distancia, relevante en escenas de baja textura.
Iluminación radial	<code>vignette_score</code>	Máscara de validez del GT	Resume viñeteado y pérdida radial de cobertura del ground truth.
Video	<code>video_lum_std</code> , <code>video_sat_max</code>	MP4 asociado	Identifican variación temporal de luminancia y máximos de saturación en movimiento.
Geometría 3D	centro de masa, componentes principales	OBJ point cloud	Permiten analizar orientación, extensión y posible alineación de nubes de puntos.

Tres variables concentran la mayor utilidad diagnóstica. Primero, `sat_pct` mide directamente la severidad de los reflejos especulares; valores altos indican píxeles donde el modelo difícilmente podrá inferir estructura del tejido. Segundo, `depth_valid_pct` resume la proporción de ground truth utilizable; su correlación negativa con `sat_pct` sugiere que la saturación está relacionada con la invalidez de profundidad. Tercero, `inpaint_ssim` permite identificar keyframes donde la corrección de especulares será más invasiva y, por tanto, donde el baseline sin corrección podría fallar con mayor probabilidad.

Normalización y transformaciones

El segundo criterio de la rúbrica exige escalar o transformar variables para garantizar comparabilidad, reducir la influencia de outliers y mejorar la convergencia de los algoritmos. En este avance se aplicaron tres decisiones principales: cap de profundidad a 150 mm, transformación logarítmica $\log(Z+1)$ y normalización min-max ajustada exclusivamente sobre el conjunto de entrenamiento.

El cap a 150 mm elimina valores físicamente improbables para el contexto laparoscópico con sistema da Vinci. Los valores mayores a dicho umbral se interpretaron como artefactos de reconstrucción asociados con reflejos, oclusiones o fallas de triangulación, por lo que se reemplazaron por valores nulos antes de calcular estadísticas. Esta decisión evita que outliers extremos distorsionen los percentiles, la transformación logarítmica y la posterior normalización.

La transformación $\log(Z+1)$ se aplicó porque la distribución de profundidad presenta sesgo positivo: la mayoría de las observaciones se concentran en distancias intermedias, mientras que existe una cola hacia valores altos. El logaritmo comprime esa cola, reduce asimetría y produce una escala más estable para los optimizadores. La suma de uno evita problemas con valores cercanos a cero y mantiene el dominio definido.

Cabe destacar que este umbral de 150 mm es un hiperparámetro específico para la cámara da Vinci (dataset SCARED); el pipeline tensorial está diseñado modularmente para que este valor se ajuste a 100 mm durante la fase de evaluación de generalización sobre el dataset C3VDv2.

Finalmente, la normalización min-max se ajustó solo con los datasets de entrenamiento. Esta regla es metodológicamente crítica porque impide la fuga de información del conjunto de prueba hacia el entrenamiento. Si el scaler se ajustara con train y test simultáneamente, el modelo tendría acceso indirecto a la distribución de los datos de evaluación, comprometiendo la validez experimental.

Tabla 3. Transformaciones aplicadas y fundamento metodológico.

Transformación	Variable o tensor afectado	Objetivo	Riesgo que controla
Cap a 150 mm	Mapa de profundidad Z	Excluir valores no plausibles o artefactuales.	Outliers y errores de reconstrucción.
$\log(Z+1)$	Profundidad válida	Comprimir cola derecha y estabilizar escala.	Sesgo positivo y dominancia de valores altos.
MinMaxScaler	Features numéricas / tensores	Llevar variables a escala comparable.	Desbalance de magnitudes y problemas de convergencia.
Fit solo en train	Scaler del pipeline	Evitar que el test influya en la parametrización.	Data leakage y evaluación optimista.

La normalización también debe interpretarse en relación con el diseño experimental. El split train/test no es aleatorio por imagen, sino que separa datasets y sujetos. Esto implica que el conjunto de prueba puede tener una distribución distinta a la de entrenamiento. Por ello, ajustar el escalador únicamente con train no es una formalidad técnica, sino una condición necesaria para evaluar generalización intersujeto de manera más realista.

Selección y extracción de características

El tercer criterio de la rúbrica se cubre mediante métodos de filtrado y extracción alineados con los resultados exploratorios. El avance aplicó correlación de Pearson para identificar redundancia, VarianceThreshold para detectar variables con baja variabilidad y PCA geométrico para extraer estructura dominante de la nube de puntos 3D.

La correlación de Pearson permitió identificar pares de variables altamente redundantes. En particular, `log_depth_median` mostró correlación casi perfecta con `depth_median`, lo cual es esperable porque se trata de una transformación monótona de la misma variable. De igual forma, los canales `r_mean`, `g_mean` y `b_mean` mostraron alta intercorrelación, ya que la coloración del tejido hace que los canales varíen de forma conjunta. La decisión fue conservar variables resumidas e interpretables, como `lum_mean` y `rb_balance`, en lugar de depender de canales crudos redundantes.

VarianceThreshold se utilizó para identificar características con varianza inferior a 0.01. El análisis mostró que `video_lum_std` y `video_sat_max` pueden colapsar artificialmente cuando se imputan con cero los keyframes sin video. Por tanto, la decisión metodológica no fue eliminarlas de forma absoluta, sino mantenerlas en el dataframe completo y excluirlas únicamente de análisis que requieren completitud. Esta distinción es importante, porque evita perder información temporal valiosa en los keyframes donde el video sí está disponible.

El PCA geométrico se aplicó sobre los vértices XYZ del archivo `point_cloud.obj`. A diferencia de la selección de variables tabulares, aquí el objetivo fue extraer una representación geométrica compacta del tejido: eje principal de extensión, eje secundario de curvatura y componente perpendicular al plano local. Esta extracción aporta una base para alinear nubes de puntos estimadas y reales antes de calcular Chamfer Distance en la fase de evaluación.

Tabla 4. Métodos de selección/extracción y decisiones adoptadas.

Método	Criterio	Resultado observado	Decisión metodológica
Correlación de Pearson	$ r > 0.8$ para redundancia	log_depth_median y depth_median casi equivalentes; canales RGB intercorrelacionados.	Excluir variables redundantes en análisis secundarios y conservar resúmenes interpretables.
VarianceThreshold	Varianza < 0.01	Features de video colapsan por ausencia de video en 5/20 keyframes.	Mantenerlas en dataframe, pero no usarlas en análisis que exigen datos completos.
PCA geométrico	Componentes principales de XYZ	PC1 describe mayor extensión del tejido; PC2 curvatura; PC3 profundidad perpendicular.	Usar vectores propios como referencia potencial para alineación y Chamfer Distance.

Estas decisiones reducen complejidad sin perder interpretabilidad. Además, conectan la ingeniería de características con la fase de modelado: las variables seleccionadas ayudarán a identificar keyframes de referencia, casos difíciles, artefactos de iluminación y criterios de comparación entre métodos de corrección. En términos prácticos, el avance no solo produce features; produce criterios de decisión para el experimento completo.

Relación con modelos posteriores

El pipeline definido prepara el terreno para comparar cuatro condiciones de entrada: sin corrección, CLAHE, Retinex y MonolIT (Espinosa et al., 2025). Estas condiciones funcionarán como variable independiente antes de alimentar los modelos de profundidad. La literatura respalda esta elección: CLAHE se justifica como técnica de mejora adaptativa de contraste local (Pizer et al., 1987), mientras que Retinex permite abordar la separación entre iluminación y reflectancia (Land & McCann, 1971). En el contexto endoscópico, los reflejos especulares y la iluminación direccional son problemas recurrentes que afectan la segmentación, la reconstrucción y la estimación de profundidad (Nie et al., 2023; Shao et al., 2022).

La selección de modelos posteriores también tiene fundamento. EndoDepthAndMotion es pertinente porque integra profundidad, seguimiento y reconstrucción en videos endoscópicos mediante restricciones fotométricas (Recasens et al., 2021). EndoGaussian resulta relevante como línea reciente de reconstrucción endoscópica basada en Gaussian Splatting, con énfasis en escenas dinámicas y eficiencia de renderizado (Liu et al., 2024). Por su parte, NeXF se conserva como parte del diseño experimental propuesto para comparar modelos de profundidad y reconstrucción bajo distintas condiciones de iluminación (Niemeyer et al., 2025).

Repositorio de GitHub y artefactos generados

El repositorio centraliza el notebook de ingeniería de características, el reporte técnico en Markdown y los archivos generados durante el análisis. Esta organización contribuye a la reproducibilidad, ya que permite rastrear el paso de datos crudos a dataframe, transformaciones, selección de variables y visualizaciones diagnósticas.

Repositorio principal: https://github.com/jmtoral/proyecto_integrador_52

Notebook utilizado: [notebooks/Avance2_52_Feature_Engineering.ipynb](#)

Reporte técnico: [reports/02_reporte_feature_engineering.md](#)

Tabla 5. Artefactos esperados y uso en el Avance 3.

Artefacto	Ubicación / origen	Uso posterior
Dataframe df	Generado en notebook	Diagnóstico de calidad y selección de keyframes.
Pipeline cap + log + scaler	Celdas de preprocesamiento	Aplicación homogénea antes del entrenamiento.
vignette_score	Columna del dataframe	Identificación de keyframes afectados por viñeteado.
inpaint_ssim	Columna del dataframe	Detección de casos donde la supresión de especulares altera la estructura.
PCA geométrico	Nube de puntos OBJ	Alineación potencial para Chamfer Distance.
Reporte Markdown	reports/02_reporte_feature_engineering.md	Documentación técnica y trazabilidad del avance.

Conclusiones

La fase de ingeniería de características permitió convertir un conjunto de datos visual, volumétrico y parcialmente incompleto en una representación analítica útil para tomar decisiones antes del modelado. El aporte central del avance no está únicamente en generar nuevas columnas, sino en justificar qué mide cada variable y por qué es relevante para un problema de estimación de profundidad endoscópica bajo iluminación no controlada.

Desde la perspectiva de CRISP-ML(Q), el avance reduce riesgos técnicos al documentar la calidad de los keyframes, la proporción de ground truth válido, la severidad de los reflejos especulares, la presencia de viñeteado y la redundancia entre variables. Esto evita que los modelos posteriores sean evaluados sin conocer previamente las condiciones de entrada. Además, la normalización ajustada solo en train fortalece la validez experimental al prevenir data leakage.

El análisis también deja claro que los reflejos especulares no son un defecto cosmético de la imagen, sino una fuente de pérdida de información geométrica. Por ello, las variables `sat_pct`, `depth_valid_pct` e `inpaint_ssim` serán fundamentales para interpretar por qué ciertos keyframes pueden beneficiarse más de correcciones como CLAHE, Retinex o MonolIT. En el siguiente avance, estas decisiones deberán conectarse con métricas de desempeño como AbsRel, RMSE y Chamfer Distance.

Conclusiones del equipo

Elda Cristina Morales Sánchez de la Barquera -



“Este avance me permitió comprender que la calidad de los datos no puede asumirse como una condición previa, sino que debe construirse, medirse y documentarse antes de entrenar cualquier modelo. En imágenes endoscópicas, los reflejos especulares afectan tanto la apariencia visual como la disponibilidad del ground truth, por lo que la ingeniería de características se vuelve una fase crítica para anticipar sesgos y posibles errores.

Considero valioso que el proyecto no avance directamente al modelado, sino que primero establezca criterios de calidad, normalización y selección que harán más sólida la comparación posterior entre métodos de corrección y modelos de profundidad.”

María Paula Gutiérrez Cervantes -



“Esta etapa nos deja grandes aprendizajes sobre el verdadero valor de la preparación de datos. Aunque entendíamos el problema, al tener un análisis de estas imágenes a fondo aprendimos de primera mano cómo los reflejos especulares realmente destruyen la información geométrica. Construir estos indicadores matemáticos paso a paso nos permite entender el comportamiento de nuestro ground truth a un nivel mucho más profundo. Todo este trabajo previo nos deja una base sumamente sólida y

objetiva para la siguiente fase, asegurando que nuestras futuras comparaciones entre los modelos 3D estén respaldadas por datos que ahora comprendemos de mejor manera.”

José Manuel Toral Cruz



“La ingeniería de características de datos no tabulares implican un conjunto de desafíos: cómo y para qué hacer transformaciones. Esos desafíos impactan en cómo debemos diseñar el pipeline de consumo y entrenamiento, ya que no sólo es normalizar un vector de observaciones, sino que la transformación de un elemento del dataset tiene consecuencias en el resto. Así, el siguiente avance es el punto de quiebre entre todo lo que sabíamos y la verdadera razón de ser del proyecto.”

Referencias

- Allan, M., Mcleod, J., Wang, C., Rosenthal, J. C., Hu, Z., Gard, N., Eisert, P., Fu, K. X., Zeffiro, T., Xia, W., Zhu, Z., Luo, H., Jia, F., Zhang, X., Li, X., Sharan, L., Kurmann, T., Schmid, S., Sznitman, R., Psychogyios, D., Azizian, M., Stoyanov, D., Maier-Hein, L., & Speidel, S. (2021). Stereo correspondence and reconstruction of endoscopic data challenge. arXiv. <https://arxiv.org/abs/2101.01133>
- Espinosa, R., Ochoa-Ruiz, G., & Daul, C. (2025). *Transformer-based illumination invariant self-supervised monocular depth estimation in endoscopy*. SSRN. <https://doi.org/10.2139/ssrn.5189985>
- Gonzalez, R. C., & Woods, R. E. (2018). Digital image processing (4th ed., Global ed.). Pearson.
- Land, E. H., & McCann, J. J. (1971). Lightness and retinex theory. Journal of the Optical Society of America, 61(1), 1-11. <https://doi.org/10.1364/JOSA.61.000001>
- Liu, Y., Li, C., Yang, C., & Yuan, Y. (2024). EndoGaussian: Real-time Gaussian splatting for dynamic endoscopic scene reconstruction. arXiv. <https://arxiv.org/abs/2401.12561>
- Nie, C., Xu, C., Li, Z., Chu, L., & Hu, Y. (2023). Specular reflections detection and removal for endoscopic images based on brightness classification. *Sensors*, 23(2), Artículo 974. <https://doi.org/10.3390/s23020974>
- Pizer, S. M., Amburn, E. P., Austin, J. D., Cromartie, R., Geselowitz, A., Greer, T., ter Haar Romeny, B., Zimmerman, J. B., & Zuiderveld, K. (1987). Adaptive histogram equalization and its variations. *Computer Vision, Graphics, and Image Processing*, 39(3), 355-368. [https://doi.org/10.1016/S0734-189X\(87\)80186-X](https://doi.org/10.1016/S0734-189X(87)80186-X)
- Recasens, D., Lamarca, J., Fácil, J. M., Montiel, J. M. M., & Civera, J. (2021). *Endo-Depth-and-Motion: Reconstruction and tracking in endoscopic videos using depth networks and photometric constraints*. arXiv. <https://arxiv.org/abs/2103.16525>
- Shao, S., Pei, Z., Chen, W., Zhu, W., Wu, X., Sun, D., & Zhang, B. (2022). Self-supervised monocular depth and ego-motion estimation in endoscopy: Appearance flow to the rescue. *Medical Image Analysis*, 77, Artículo 102338. <https://doi.org/10.1016/j.media.2021.102338>

- Studer, S., Bui, T. B., Drescher, C., Hanuschkin, A., Winkler, L., Peters, S., & Müller, K.-R. (2021). Towards CRISP-ML(Q): A machine learning process model with quality assurance methodology. *Machine Learning and Knowledge Extraction*, 3(2), 392-413. <https://doi.org/10.3390/make3020020>
- Yu, B., Chen, W., Zhong, Q., & Zhang, H. (2021). Specular highlight detection based on color distribution for endoscopic images. *Frontiers in Physics*, 8, Artículo 616930. <https://doi.org/10.3389/fphy.2020.616930>
- Niemeyer, M., Manhardt, F., Rakotosaona, M.-J., Oechsle, M., Tsalicoglou, C., Tateno, K., Barron, J. T., & Tombari, F. (2025). Learning neural exposure fields for view synthesis. En *Proceedings of the 39th Conference on Neural Information Processing Systems (NeurIPS 2025)*. <https://m-niemeyer.github.io/nexf>